



난임 데이터 해커톤 도메인 가이드북

도메인 지식 없는 팀원을 위한 친절한 안내서

29~52번 피처 완전 정복 + 이전 피처 보강

이 문서는 다음을 다룹니다

- 5분 만에 배우는 난임 시술 전체 흐름
- 29~52번 피처 각각의 의학적·데이터적 의미
- 이전에 다룬 피처들의 보강 포인트
- 전처리 체크리스트와 파생변수 레시피
- 해커톤 발표용 스토리 아이디어

목차

Chapter 0	5분 만에 배우는 난임 시술	p.3
Chapter 1	29~38. 시술·임신·출산 횟수 (보강)	p.8
Chapter 2	39~46. 배아 생성과 활용 피처	p.10
Chapter 3	47~52. 난자·정자 관련 피처	p.16
Chapter 4	이전 피처에서 놓친 포인트	p.20
Chapter 5	전체 전처리 체크리스트	p.24
Chapter 6	발표용 스토리 아이디어	p.26

이 문서 읽는 법

각 피처 설명은 다음 4가지 관점으로 구성했습니다:

항목	설명
쉽게 말하면	의학 용어 없이 일상 언어로 설명
의학적 의미	이 수치가 임신·출산 성공과 어떻게 연결되는지
데이터에서는	분포·결측·특이값 등 데이터 관점
활용 포인트	피처 엔지니어링과 모델링 활용법

5분 만에 배우는 난임 기술

데이터를 제대로 다루려면 배경 지식이 필요해요. 의학 용어를 최대한 걷어내고, 전체 그림부터 그려볼게요.

0.1 임신이 되는 기본 원리

자연 임신은 단순해 보여도 여러 단계를 거쳐야 성공합니다. 하나라도 막히면 난임이 돼요.

단계	이름	무슨 일이 일어나나
1	배란	여성 몸에서 난자가 배출됨 (한 달에 1~2개)
2	수정	나팔관에서 난자와 정자가 만남
3	세포 분열	수정란이 분열하며 배아가 됨
4	착상	배아가 자궁벽에 붙음
5	유지	10개월간 임신 유지 → 출산

이 중 어느 단계라도 문제가 생기면 난임이 발생해요. 예를 들어 배란이 안 되거나(배란 장애), 나팔관이 막혔거나(난관 불임), 정자 수가 적거나(남성 요인), 자궁 환경이 안 좋거나(착상 장애) 등 원인이 다양합니다.

0.2 난임 기술의 3가지 종류

난임 기술은 '어느 단계를 대신해주는가'에 따라 구분돼요. 복잡도가 낮은 것부터 높은 순으로:

기술명	방법	역할	성공률
IUI (인공수정)	정자를 자궁에 직접 넣어줌	나팔관까지만 도와줌	10~15%
IVF (체외수정)	난자+정자를 실험실에서 만남시킴	수정 단계를 대신	25~30%
ICSI (미세주입술)	정자를 난자에 직접 주입	수정을 강제로 시킴	27~30%

데이터 맥락

이 데이터셋의 **기술유형** 컬럼에서 IVF는 체외수정 전체를 의미하고 (ICSI도 IVF의 일종), DI는 기증 정자를 사용한 인공수정을 의미합니다. **특정기술유형**에서 세부 기법(ICSI, IVF, IUI 등)이 구분돼요.

0.3 IVF 시술 7단계 타임라인

체외수정(IVF)은 약 2~3주에 걸쳐 진행됩니다. 각 단계가 데이터 컬럼과 직접 연결돼요.

1	배란 유도 약물(호르몬제)로 여러 개의 난포를 동시에 키움. 자연 상태에서는 1~2개지만 시술에서는 10개 이상 키우기도 함. 관련 컬럼: 배란 유도 유형(#07)
2	난자 채취 난포에서 난자를 바늘로 뽑아냄 (수면마취). 관련 컬럼: 수집된 신선 난자 수(#48), 난자 채취 경과일
3	정자 준비 남편의 정자를 받아 활동성 좋은 것만 선별. 또는 기증 정자를 해동해서 준비. 관련 컬럼: 정자 출처
4	수정 IVF는 살레에 섞어놓고 자연 수정을 기다림. ICSI는 정자 하나를 난자에 직접 주입. 관련 컬럼: 혼합된 난자 수(#50), 미세주입된 난자 수(#40)
5	배양 수정란을 3~6일간 배양기에서 키움. Day 3(분할기)까지만 키우거나, Day 5~6(배반포)까지 키움. 관련 컬럼: 총 생성 배아 수(#39), 배아 발달 단계
6	이식 또는 동결 질 좋은 배아를 자궁에 이식(1~3개). 나머지는 동결 보관하거나 폐기. 관련 컬럼: 이식된 배아 수(#42), 저장된 배아 수(#44)
7	착상 및 확인 2주 후 임신 호르몬(hCG) 검사로 임신 여부 확인. 예측 타겟: 임신 성공 여부

타임라인이 왜 중요한가

데이터의 많은 컬럼들이 이 7단계 중 어느 시점의 기록인지를 담고 있습니다. 예를 들어 '경과일' 컬럼들은 각 단계 사이의 시간을, '난자 수'와 '배아 수' 컬럼들은 각 단계에서 몇 개가 남았는지를 나타내요. 단계가 뒤로 갈수록 개수가 줄어드는 구조예요 (채취 난자 > 수정 성공 > 배아 > 이식).

0.4 핵심 용어 사전

앞으로 자주 나올 용어들을 먼저 정리해놓을게요. 헛갈리면 여기로 돌아오세요.

용어	의미
배아 (Embryo)	정자+난자가 만나 형성된 초기 생명. 수정 후 8주까지
난포 (Follicle)	난자를 품고 있는 주머니. 배란 유도로 여러 개 키움
배반포 (Blastocyst)	배양 5~6일차 배아. 이식 성공률이 가장 높은 단계
분할기 (Cleavage)	배양 2~3일차 배아. 세포 4~8개 단계
착상 (Implantation)	배아가 자궁벽에 붙는 과정. 이게 되어야 임신
동결/해동 (Freeze/Thaw)	배아·난자를 영하 196℃ 액체질소에 보관 후 재사용
미세주입 (ICSI)	정자 1개를 난자에 직접 주사하는 수정법
신선 주기 (Fresh cycle)	채취 → 수정 → 바로 이식 (동결 없음)
동결 주기 (FET)	이전에 동결한 배아를 녹여서 이식
자궁내막 (Endometrium)	자궁 내벽. 배아가 착상하는 곳. 두께가 중요
hCG	임신 확인 호르몬. 수치로 임신 여부와 건강 상태 판단
PGT-A / PGT-M	착상 전 유전 검사(A=염색체)/진단(M=특정 질환)

29~38. 시술·임신·출산 횟수 (보강)

앞서 상세히 다룬 컬럼 그룹입니다. 여기서는 핵심 요약과 함께 놓쳤을 수도 있는 포인트를 짚어드려요.

1.1 컬럼 구조 요약

10개 컬럼이 3×3 매트릭스 구조로 설계돼 있어요 (+ IVF·DI 외 기타 출산).

	시술 횟수	임신 횟수	출산 횟수
전체 (합계)	#29 총 시술	#32 총 임신	#35 총 출산
IVF 관련	#30 IVF 시술	#33 IVF 임신	#36 IVF 출산
DI 관련	#31 DI 시술	#34 DI 임신	#37 DI 출산

1.2 꼭 기억할 5가지

1. 문자열 → 숫자 변환 필수

모든 값이 '0회', '1회', ..., '6회 이상' 형태의 문자열입니다. 정수로 바꿔야 모델이 쓸 수 있어요. '6회 이상'은 6으로 변환 + `is_censored` 플래그를 추가해야 정보 손실을 막습니다.

2. 과거 출산 경험 = 최강 긍정 신호

`ever_delivered`(총 출산 > 0) 플래그는 이 데이터셋에서 가장 강력한 예측 변수 중 하나입니다. 과거에 출산했다는 건 '임신과 출산이 가능한 몸'이라는 증거이거든요. Templeton 1996, Barnett-Itzhaki 2020 등 수십 년 연구로 입증됨.

3. 3회 이상 반복 = 강한 부정 신호

`repeated_3plus`(총 시술 ≥ 3) 플래그. 3회 시도에도 성공 못한 환자는 근본적 난임 요인이 강하다는 뜻. 4, 5, 6회 갈수록 성공률 계속 떨어집니다.

4. 전환율 피처가 차별화 포인트

단순 횟수보다 '임신 전환율 = 총 임신 / (총 시술 + 1)'이 환자의 예후를 더 잘 나타냅니다. 시술해도 임신이 안 되는 환자 vs 임신은 되는데 유산하는 환자는 완전히 다른 문제를 가진 거예요.

5. 유산 경험 정보 추출

유산 횟수 = 총 임신 - 총 출산으로 계산 가능. 반복 유산은 단순 난임과 다른 자궁/면역 문제를 시사합니다. ever_delivered와 별개로 중요한 신호예요.

39~46. 배아 생성과 활용 피처

컬럼 번호는 참고용

실제 데이터의 컬럼 번호와 순서가 다를 수 있어요. 중요한 건 **배아 관련 피처들의 구조와 관계**입니다. 아래 설명을 데이터에 있는 실제 컬럼명과 매칭해서 활용하세요.

2.1 배아 파이프라인 이해하기

IVF에서 난자 → 배아 → 이식까지의 흐름을 숫자로 추적할 수 있어요. 각 단계에서 **개수가 계속 줄어드는 구조**를 이해하는 게 핵심입니다.

단계	예시 수치	줄어드는 이유
① 채취한 난자	10개	배란 유도로 여러 개 채취
② 성숙 난자	8개	미성숙 난자 제외
③ 수정된 난자	6개	수정 실패한 것 제외
④ 생성된 배아	5개	배양 중 발달 멈춘 것 제외
⑤ 이식 가능한 배아	3개	품질 기준 미달 제외
⑥ 실제 이식된 배아	1~2개	한 번에 1~2개만 이식
⑦ 저장된 배아	1~2개	남은 것 동결 보관

이 감소 패턴 자체가 강력한 신호예요. '채취→수정' 비율이 낮으면 정자/난자 질이 나쁘다는 뜻이고, '수정→배아' 비율이 낮으면 배아 발달력이 떨어진다는 뜻입니다.

2.2 피처별 상세 설명

#39. 총 생성 배아 수

쉽게 말하면

이번 시술에서 실험실에서 만들어낸 배아의 총 개수예요. 많을수록 선택지가 많아서 좋지만, 꼭 많다고 성공하는 건 아닙니다.

의학적 의미

난자 수와 정자 질, 배양 환경이 모두 좋아야 많이 만들어집니다. 일반적으로 채취한 난자의 50~70%가 배아까지 도달해요. 고령일수록, 난소 기능이 낮을수록 이 숫자가 작아집니다.

데이터에서는

정수값 (보통 0~20). **0인 경우**는 수정이 아예 실패했거나 배양 중 모두 탈락한 케이스 → 성공률 매우 낮음. 결측값은 DI 시술이거나 배아를 만들지 않은 케이스일 수 있어요.

활용 포인트

파생변수 추천:

- 배아_있음 = (총 생성 배아 수 > 0) — 기본 플래그
- 배아_풍부 = (총 생성 배아 수 >= 5) — 양질의 사이클
- 배아_생성률 = 총 생성 배아 수 / (수집된 난자 수 + 1) — 효율성

추가 팁

이 컬럼이 0인데 이식된 배아 수가 양수라면 데이터 오류거나 동결 배아 이식(FET) 케이스일 수 있어요. 교차 검증 필수!

#40. 미세주입된 난자 수 (ICSI)

쉽게 말하면

ICSI 방식으로 정자를 직접 주입한 난자의 개수예요. 일반 IVF는 살레에 섞어놓지만, ICSI는 하나하나 주사해요.

의학적 의미

주로 남성 요인 난임(정자 수 적음, 운동성 낮음)에 사용. 일반 IVF보다 수정률이 안정적이지만 배아 발달률은 비슷합니다. 최근엔 ICSI 사용 비율이 높아지는 추세예요.

데이터에서는

정수값. 0이면 ICSI 안 했다는 뜻 (일반 IVF 또는 DI). 값이 있다면 **특정시술유형이 ICSI 계열일** 가능성이 높아요. 다른 컬럼(특정시술유형)과 교차 검증하면 일관성 확인 가능.

활용 포인트

파생변수 추천:

- is_ICSI = (미세주입된 난자 수 > 0)
- ICSI_비율 = 미세주입 난자 수 / (혼합된 난자 수 + 미세주입 난자 수 + 1)
→ 이 시술에서 ICSI와 일반 IVF를 어떤 비율로 썼는지

추가 팁

남성 요인 불임(#11, #12) 플래그와 **ICSI 사용**이 같이 있으면 '원인에 맞는 적절한 시술' = 긍정 신호. 반대로 남성 요인인데 ICSI 안 했다면 부적합 케이스로 볼 수 있어요.

#41. 미세주입에서 생성된 배아 수

쉽게 말하면

ICSI로 수정한 난자 중에서 배아까지 발달한 개수예요. 'ICSI 성공률'을 나타내는 직접적인 수치입니다.

의학적 의미

ICSI 수정률은 보통 70~80% 수준. 이 숫자가 미세주입 난자 수보다 많이 작으면 수정 실패 또는 초기 발달 이상을 의미해요. 정자 DNA 손상이나 난자 질 저하가 원인일 수 있습니다.

데이터에서는

미세주입된 난자 수(#40)보다 작거나 같아야 정상. **논리적 제약:** $\#41 \leq \#40$. 만약 $\#41 > \#40$ 이면 데이터 오류예요.

활용 포인트

핵심 파생변수:

- $\text{ICSI_수정률} = \#41 / (\#40 + 1)$
→ ICSI의 효율성. 낮으면 정자/난자 질 문제 시사
- $\text{ICSI_실패수} = \#40 - \#41$
→ 주입했는데 배아 안 된 개수

추가 팁

이 비율이 평균보다 현저히 낮으면 '예후 나쁨' 신호. 일반 IVF와 ICSI 수정률을 비교하면 '이 환자는 어느 방식이 나았을까'도 분석 가능해요.

#42. 이식된 배아 수

쉽게 말하면

실제로 자궁에 넣은 배아의 개수. 보통 1~3개예요. 많이 넣으면 성공률 올라가지만 쌍둥이 위험도 같이 올라갑니다.

의학적 의미

최신 프로토콜은 '단일 배아 이식(SET)'을 권장해요. 질 좋은 배반포 1개가 분할기 배아 3개보다 낫거든요. 0인 경우는 이식이 취소된 케이스 (배아 전부 동결 또는 품질 미달).

데이터에서는

정수값 0~3이 일반적, 최대 5까지 가능. 0 = 이식 취소 → 이번 시술로는 임신 불가 → 성공률 0%에 가까움. 1 = 최신 프로토콜 또는 배아 부족. 2~3 = 전통적 방식 또는 고령 환자.

활용 포인트

핵심 파생변수:

- 이식_취소 = (이식 배아 수 == 0) — 강한 부정 신호
- 단일_이식 = (이식 배아 수 == 1) — 현대식 프로토콜
- 다중_이식 = (이식 배아 수 >= 2) — 전통적 또는 보수적
- 이식_비율 = 이식 배아 수 / (총 생성 배아 수 + 1)

추가 팁

이 데이터의 가장 중요한 컬럼 중 하나예요. 이식 배아 수와 배아 발달 단계(분할기 vs 배반포)를 조합하면 예후 예측력이 크게 올라갑니다.

#43. 미세주입 배아 이식 수

쉽게 말하면

이식한 배아 중 ICSI로 만든 배아의 개수예요. 전체 이식된 배아 수(#42)의 부분집합입니다.

의학적 의미

대부분의 경우 한 시술에서 한 방식만 쓰지만, 드물게 IVF 배아와 ICSI 배아를 섞어서 이식하기도 해요. #42(전체 이식)와 이 값을 비교하면 이식 구성을 알 수 있어요.

데이터에서는

$\#43 \leq \#42$ (전체 이식 수)여야 정상. $\#43 == \#42$: 전부 ICSI 배아 이식 (남성 요인 환자 많음). $\#43 == 0 < \#42$: 전부 일반 IVF 배아 이식. $0 < \#43 < \#42$: 혼합 이식 (드뭄).

활용 포인트

파생변수:

- $\text{ICSI_전용_이식} = (\#43 == \#42) \ \& \ (\#42 > 0)$
- $\text{ICSI_이식_비율} = \#43 / (\#42 + 1)$

이 비율이 높으면 '정자 문제가 주요 원인' 환자일 가능성 시사

#44. 저장된 배아 수

쉽게 말하면

이번에 안 쓰고 미래를 위해 동결 보관한 배아의 개수예요. '여유 배아'가 있다는 건 긍정 신호입니다.

의학적 의미

저장된 배아가 많다 = 배아를 많이 만들었고 질도 괜찮다는 뜻. 이번 시술 실패해도 다음에 FET(동결 배아 이식)로 재시도 가능. 동결 보관은 영하 196℃ 액체질소에 보관하며, 10년 이상 보관 가능해요.

데이터에서는

보통 0~10개 범위. 0인 경우는 배아가 없거나 품질 미달로 전부 폐기된 케이스. 저장 배아가 많다 = 전반적으로 양질의 사이클.

활용 포인트

파생변수:

- 동결_여유 = (저장된 배아 수 >= 2) — 예후 양호 신호
- 저장_비율 = 저장된 배아 수 / (총 생성 배아 수 + 1)
→ 만든 배아 중 몇 %를 보관했는지. 높으면 양질
- 총_배아_활용 = 이식된 배아 수 + 저장된 배아 수

추가 팁

논리 체크: (이식 + 저장) ≤ 총 생성 배아 수. 차이는 '폐기된 배아 수'예요. 폐기율이 높으면 배아 질이 나빴다는 뜻.

#45. 미세주입 난자 후 저장된 배아 수

쉽게 말하면

ICSI로 만든 배아 중에서 동결 저장된 개수예요. #44(전체 저장)의 ICSI 버전입니다.

의학적 의미

ICSI 배아의 동결 가능성은 일반 IVF 배아와 비슷해요. 이 수치는 ICSI 배아의 양산성과 질을 함께 반영합니다.

데이터에서는

$\#45 \leq \#44$ (전체 저장)여야 정상. $\#45 \leq \#41$ (생성된 ICSI 배아)여야 정상. 이 두 제약을 만족하는지 데이터 검증 필요.

활용 포인트

파생변수:

- $\text{ICSI_저장_비율} = \#45 / (\#41 + 1)$
→ ICSI 배아 중 동결 가능했던 비율. ICSI 배아 질을 반영

추가 팁

이 컬럼과 일반 IVF 저장 배아 수(#44 - #45)를 비교하면 '어느 방식이 이 환자에게 효율적이었나' 알 수 있어요.

#46. 해동된 배아 수

쉽게 말하면

이번 시술에서 과거에 저장해둔 배아를 녹여서 사용한 개수예요. 값이 있다면 이번이 FET(동결 배아 이식) 주기입니다.

의학적 의미

FET(Frozen Embryo Transfer) 주기는 신선 주기와 다른 특성을 가져요. 배란 유도 없이 자궁 내막만 준비하고 이식. 최근 연구에서 FET가 신선 주기보다 성공률 비슷하거나 더 높다는 결과도 있어요. 해동 생존율은 보통 90~95%.

데이터에서는

이 컬럼이 가장 강력한 구분자예요:

- 0 = 신선 주기 (Fresh cycle)
- > 0 = 동결 주기 (FET cycle)

이 구분은 거의 모든 다른 컬럼의 해석에 영향을 줍니다.

활용 포인트

핵심 파생변수:

- $is_FET = (해동\ 배아\ 수 > 0)$ **매우 중요**
- $is_Fresh = (해동\ 배아\ 수 == 0) \ \& \ (이식\ 배아\ 수 > 0)$
- 해동 생존 여부: (해동 수) vs (이식에 사용된 수)
- **주기별 모델링**: FET와 Fresh를 따로 학습하는 앙상블도 고려

추가 팁

is_FET 플래그는 이 데이터셋에서 **Top 5 중요 피처**가 될 가능성이 높아요. 성공률, 배란 유도 유무, 배아 특성 등 모두 이 플래그에 따라 달라집니다.

47~52. 난자·정자 관련 피처

배아가 되기 전 단계인 난자와 정자에 관한 피처들입니다. 이 숫자들은 '배아 파이프라인의 시작점' 정보를 담고 있어서, 이후 배아 관련 피처들의 '분모' 역할을 해요.

#47. 해동 난자 수

쉽게 말하면

이번 시술에서 과거에 동결해둔 난자를 녹여서 사용한 개수. 값이 있다면 동결 난자를 사용한 시술이에요.

의학적 의미

난자 동결은 항암 치료 전, 고령 임신 대비, 미혼 여성의 가임력 보존 등에 사용. 배아 동결과 달리 난자 동결은 기술적으로 더 어려워요. 해동 후 생존율이 배아보다 낮습니다(70~90%).

데이터에서는

대부분 0 (신선 난자 사용이 일반적). 값이 있으면 특수 케이스 → 희귀하지만 의미 있는 신호. 건수가 적으면 '기타' 카테고리로 묶는 것도 고려.

활용 포인트

파생변수:

- $is_동결난자 = (해동\ 난자\ 수 > 0)$
- 건수 확인 후 드물면 $is_특수케이스$ 로 통합

추가 팁

$is_FET(\#46)$ 과 다름에 주의. is_FET 은 '동결 배아 사용', 이건 '동결 난자 사용'이에요. 동결 난자를 녹여서 → 수정 → 새 배아 생성의 케이스.

#48. 수집된 신선 난자 수

쉽게 말하면

이번 주기에 난소에서 직접 채취한 난자의 개수예요. 배란 유도 결과물이라고 보면 됩니다.

의학적 의미

배란 유도 성과를 직접 나타내는 수치. 일반적으로 8~15개가 이상적. 너무 많으면(20개 이상) 난소 과자극 증후군 위험, 너무 적으면(3개 이하) 난소 반응 저하를 의미해요. 고령·난소 기능 저하 환자는 이 숫자가 작습니다.

데이터에서는

이 컬럼은 환자의 난소 예비력을 가장 잘 반영해요. 0 = 채취 실패 (시술 중단). 1~3 = 저반응군. 4~9 = 보통. 10~15 = 양호. 20+ = 과자극 위험.

활용 포인트

핵심 파생변수:

- 난소_반응_구간: 저반응 / 정상 / 과반응 범주화
- 수정_효율 = 수정된 난자 / (신선 난자 + 1)
- 배아_전환율 = 총 생성 배아 / (신선 난자 + 1)
- 채취_실패 = (신선 난자 수 == 0)

추가 팁

이 컬럼은 나이와 강한 상관을 가져요. 나이로 정규화하면 더 순수한 '난소 기능' 신호를 추출할 수 있어요. 예: 30대 여성이 5개면 저반응, 40대 여성이 5개면 정상.

#49. 저장된 신선 난자 수

쉽게 말하면

이번에 채취한 난자 중 수정 안 하고 동결 보관한 개수예요. 미래에 쓸 난자를 남겨두는 거죠.

의학적 의미

일반 IVF에서는 채취한 난자를 바로 수정시켜요. 저장하는 경우는 특수해요: 파트너 정자가 준비 안 됐거나, 환자가 일부만 즉시 사용하고 나머지는 보존하고 싶을 때. 또는 **난자 기증용**으로 저장.

데이터에서는

대부분 0. 값이 있는 케이스는 특수 목적의 시술. #28(배아 생성 주요 이유)의 'is_난자저장용'과 교차 검증 필수.

활용 포인트

파생변수:

- is_난자저장 = (저장된 신선 난자 수 > 0)
- #28의 'is_난자저장용' 플래그와 일치하는지 검증
- 실사용_난자 = 수집 - 저장

추가 팁

논리적 제약: 저장된 난자 수 $\leq$ 수집된 신선 난자 수. 위반 시 데이터 오류.

#50. 혼합된 난자 수

쉽게 말하면

일반 IVF 방식으로 정자와 섞어놓은 난자의 개수예요. ICSI(주입)가 아닌 자연 수정 방식을 쓴 난자 수.

의학적 의미

혼합(co-incubation) = 살레에 난자와 정자를 같이 넣고 자연 수정 기다림. ICSI보다 자연스럽지만 수정률이 불안정할 수 있어요. 정자 활동성이 좋은 경우 선호되는 방식.

데이터에서는

#40(미세주입된 난자)과 상호 배타적이어야 정상. **혼합 + 미세주입 $\approx$ 수집된 신선 난자** (약간 차이 가능). 두 방식을 같이 쓰는 경우도 있어요(Split-ICSI).

활용 포인트

파생변수:

- $is_일반IVF = (혼합된\ 난자\ 수 > 0) \ \& \ (미세주입\ 난자\ 수 == 0)$
- $is_Split = (혼합 > 0) \ \& \ (미세주입 > 0)$ — 혼합 방식
- $일반_수정_비율 = 혼합 / (혼합 + 미세주입 + 1)$

추가 팁

Split 방식은 '어느 방법이 나올지 모를 때' 양쪽으로 시도하는 전략. 이 케이스 환자는 수정 방식 선택에 불확실성이 있었던 거라 특이 케이스로 분류 가능.

#51. 파트너 정자와 혼합된 남자 수

쉽게 말하면

남편(파트너)의 정자로 수정 시도한 남자의 개수예요. 기증 정자가 아닌 **본인 부부의 정자**를 사용한 경우.

의학적 의미

대부분의 IVF 시술은 파트너 정자 사용. #51의 값은 #50(전체 혼합 남자)의 대부분을 차지해야 정상. 만약 파트너 정자 혼합 수가 0인데 혼합 남자는 있다면 → 기증 정자 사용.

데이터에서는

일반적으로 $\#51 \approx \#50$ (대부분의 환자가 파트너 정자 사용). 차이가 있으면 **정자 기증 케이스**를 의미해요. 이 구분이 DI 시술이나 '기증용 배아 생성' 케이스와 연결됩니다.

활용 포인트

파생변수:

- 파트너정자_비율 = $\#51 / (\#50 + 1)$
- 기증정자_사용 = $(\#50 > 0) \ \& \ (\#51 == 0)$ 또는 기증정자_혼합 = $\#50 - \#51 > 0$

추가 팁

#28(배아 생성 주요 이유)에서 'is_기증용' 플래그와 교차 검증하세요. 기증 정자 사용자는 성공률 패턴이 일반 환자와 다를 수 있어요.

#52. 기증자 정자와 혼합된 난자 수

쉽게 말하면

기증받은 정자로 수정 시도한 난자의 개수예요. #51의 '보완 컬럼'이라고 보면 됩니다.

의학적 의미

기증 정자 사용은 심한 남성 요인 불임이나 유전병 회피 목적. 이 경우 '남성 요인' 불임이지만 ICSI보다 더 근본적 해결책을 선택한 거예요. 감정적·윤리적 결정이라 이 그룹은 특수한 프로파일을 가집니다.

데이터에서는

대부분 0. 값이 있으면 특수 케이스. DI 시술과는 다른 주의 (DI는 자궁 내 직접 주입, 이건 체외 수정 후 이식).

활용 포인트

파생변수:

- $is_정자기증 = (기증자\ 정자\ 혼합\ 난자\ 수 > 0)$
- 남성_주_불임 플래그(#11)와 교차 확인 → 일치하면 적절한 매칭

추가 팁

이 컬럼과 #28의 'is_기증용', DI 시술 여부를 종합하면 '기증을 받은 환자'의 전체 프로파일이 완성돼요. 성공률 예측에 중요한 구분점이 될 수 있어요.

3.1 39~52 피처들의 관계 지도

여기까지 본 14개 피처는 서로 수학적 제약 관계를 가집니다. 이 관계를 모두 만족하는지 확인하는 것만으로도 데이터 품질 검증이 되고, 파생변수 아이디어도 얻을 수 있어요.

핵심 제약 관계

```
■ ■■ ■ ■■
    ■■■■ ■■(#41) ≤ ■■■■ ■■(#40)
    ■ ■■ ■■(#39) ≥ ■■■■ ■■(#41)
    ■■ ■■(#42) + ■■ ■■(#44) ≤ ■ ■■ ■■(#39)
    ■■■■ ■■(#43) ≤ ■■ ■■(#42)
    ■■■■ ■■(#45) ≤ ■■ ■■(#44)

■ ■■ ■ ■■
    ■■ ■■ ■■(#49) ≤ ■■ ■■ ■■(#48)
    ■■(#50) + ■■■■(#40) ≈ ■■(#48) - ■■(#49)
    ■■■ ■■ ■■(#51) ≤ ■■(#50)
    ■■■■(#51) + ■■■■(#52) ≈ ■■(#50)

■ ■■ ■■ ■■
    is_FET = ■■ ■■(#46) > 0
    is_■■■■ = ■■ ■■(#47) > 0
    is_ICSI = ■■■■ ■■(#40) > 0
    is_■■■IVF = ■■(#50) > 0 & ■■■■(#40) == 0
    is_■■■■ = ■■■ ■■ ■■(#52) > 0
```

데이터 검증 코드

```
# ■■ ■■ ■■ ■■
errors = df[
    (df['■■■■_■■'] > df['■■■■_■■']) |
    (df['■■_■■'] + df['■■_■■'] > df['■■_■■_■■']) |
    (df['■■_■■■■'] > df['■■_■■■■']) |
    (df['■■■■■■_■■'] > df['■■_■■'])
]
print(f"■■ ■■ ■ ■: {len(errors)}")

# ■■: ■■ 0. ■■■ ■■■ ■■ ■■ ■■
# '6■ ■■' ■■ censored ■■ ■■
```

이전 피처에서 놓친 포인트

앞서 다룬 1~28번 피처들 중 놓쳤거나 추가로 강조할 부분들을 정리합니다. 앞 문서를 읽은 팀원이 다시 살펴보면 좋을 내용이에요.

4.1 환자 나이 — 가장 강한 단일 변수

나이는 난임 시술 성공의 최강 예측 변수예요. 이것만큼 확실한 신호는 없습니다. 데이터에 연령 구간이 있다면 반드시 핵심 피처로 다뤄야 해요.

연령대	난자 질	IVF 성공률	특징
20대~34세	최상	35~45%	표준 프로토콜, 양질의 배아
35~37세	양호	30~35%	이식 개수 증가 고려
38~40세	감소	20~25%	PGT-A 권장 시작
41~42세	빠른 감소	10~15%	단일 시도로 성공 어려움
43세 이상	심각한 감소	5% 이하	기증 난자 고려

나이 피처 활용 팁

- 범주화: 구간별로 비선형 효과가 크므로 단순 숫자보다 범주형이 유리
- 나이 × 시술 횟수: '고령 + 반복 시도'는 최악 조합
- 나이 × 난소 반응: 같은 난자 개수라도 나이에 따라 해석 다름
- 기증 여부 프록시: 43세 이상 성공 케이스는 기증 난자일 가능성

4.2 시술 유형 (#04~05) 보강

앞서 설명한 IVF/DI 대분류와 특정시술유형 외에 놓치기 쉬운 포인트:

콜론(:) 패턴의 재시도 의미

'ICSI:ICSI', 'IVF:IVF' 같은 콜론 포함 값은 같은 방식 반복을 의미. 성공률이 1% 수준으로 매우 낮음 → '이미 실패한 환자' 마커. 이 패턴 플래그를 만들면 강력한 부정 신호가 됩니다.

슬래시(/) 패턴의 발달 단계

'ICSI/BLASTOCYST', 'IVF/BLASTOCYST'는 배반포까지 키운 고급 프로토콜. 성공률 35% 이상으로 크게 높음. is_배반포 플래그는 중요한 긍정 신호.

Unknown의 위치

특정시술유형 'Unknown' 23.7% 성공률은 평균보다 살짝 낮지만 특이하지 않음. 제거하지 말고 별도 카테고리로 유지. Unknown은 기록 누락이지 '나쁜 신호'가 아닐 수 있음.

4.3 불임 원인 (#11~17) 보강

앞서 '원인 주체×심각도×시술' 조합을 다뤘는데, 추가로 중요한 포인트들:

원인별 시술 매칭 점수

불임 원인과 시술 방법이 맞아야 성공률이 올라가요. 핵심 매칭:

- 남성 요인 → ICSI가 적합 (정자 직접 주입)
- 여성 배란 장애 → 배란 유도 약물 + IVF
- 난관 불임 → IVF가 필수 (나팔관 우회)
- 자궁내막증 → 장기 GnRH agonist + IVF

파생변수: 'is_적절매칭' = 원인과 시술이 의학적으로 일치하는지

불명 원인의 양면성

원인 불명(#17)은 두 얼굴을 가져요:

- **긍정 해석:** 심각한 의학적 문제 없음 → 의외로 성공률 괜찮음
- **부정 해석:** 진단 못한 숨은 문제가 있음 → 예측 불가

데이터로 성공률 확인해서 어느 쪽인지 판단 필요.

부부 원인의 희소성

'부부 주/부 원인'(#15, #16)은 매우 드물어요. 면역학적 거부반응, 원인불명 호환성 문제 등 진단이 어려운 케이스. 건수 적으면 '기타 원인'과 통합 고려.

4.4 경과일 피쳐들 (별도 그룹)

데이터에 '~경과일' 형태 컬럼들이 있다면 (예: 난자 채취 경과일, 배아 이식 경과일), 이것들도 중요한 신호를 담고 있어요.

컬럼 종류	의미	해석
난자 채취 경과일	배란 유도 시작 ~ 채취까지	9~14일 정상, 짧거나 길면 특이
배아 이식 경과일	채취 ~ 이식까지	3일=분할기, 5~6일=배반포
배아 해동 경과일	동결 ~ 해동까지	긴 보관 후 해동은 생존율 영향
난자 해동 경과일	난자 동결 ~ 해동	희귀, 특수 케이스 지표
난자 혼합 경과일	채취 ~ 수정까지	당일 수정이 표준

경과일 파생변수 아이디어

- is_배반포_이식: 이식 경과일 ≥ 5 (배양 5일 이상)
- 이식_지연: 경과일이 평균보다 2일 이상 긴 경우 (배아 대기)
- 동결_기간: 저장에서 해동까지 기간 (긴 보관 = 오래된 배아)

4.5 배아 생성 주요 이유 (#28) 심화

앞서 multi-hot flag 분해 방법을 다뤘는데, 더 파고들 포인트:

'기증' 방향성의 정밀 구분

앞서 지적한대로 '기증' 플래그는 수혜/공여 구분이 중요해요. 이를 위해:

- 수혜자: is_기증용 == 1 & 다른 기증 관련 컬럼에도 표시 있음
- 공여자: is_기증용 == 1이지만 다른 기증 컬럼 비어있고 본인 시술 없음
- 성공률 패턴이 두 그룹에서 크게 다를 수 있음 → 반드시 분리

연구용 vs 저장용 vs 시술용의 시간 구조

배아 생성 목적은 '시간 순서'도 중요해요:

- 즉시 사용: 시술용 → 이번 주기 이식
- 단기 보관: 배아 저장용 → 1~2년 내 FET 계획
- 장기 보관: 난자 저장용 → 5년 이상 미래 사용
- 영구 미사용: 기증·연구용 → 본인 임신 목적 없음

이 시간축을 피쳐로 반영하면 예후 예측력 향상

4.6 'XX 이상' / '알 수 없음' 값 통합 원칙

이 데이터셋 곳곳에 상한 도달 또는 결측 표시 값이 있어요. 일관된 처리 원칙을 세워두면 실수 줄일 수 있습니다.

상황	원본 값 예시	처리 방법
숫자의 상한	'6회 이상'	6 + is_censored 플래그
카테고리 회귀값	'생식선 자극 호르몬' 1건	'알 수 없음'에 통합
알 수 없음	'Unknown', '알 수 없음'	별도 카테고리 유지
결측 (NaN)	비어있는 셀	구조적 의미 있으면 '해당없음', 아니면 보간
'해당없음'	DI 시술의 배아 컬럼	명시적 '해당없음' 값 부여

핵심 원칙

결측에는 항상 이유가 있다. 그 이유를 피처로 만들어라.

- '배란 유도 유형' NaN → FET 사이클이라 유도 없음 → is_FET으로 연결
- '배아 관련' NaN → DI 시술이라 배아 없음 → is_DI로 연결
- '유전 검사' NaN → 시행 안 함 (일반적) → 결측이 정상

데이터의 '비어있음'을 '없는 정보'가 아닌 '구조적 정보'로 다루세요.

전체 전처리 체크리스트

해커톤 제출 전에 반드시 확인해야 할 전처리 체크리스트입니다. 순서대로 진행하면 빠진 것 없이 완성할 수 있어요.

Phase 1. 데이터 이해 (시작 전 필수)

전체 row 수, column 수 확인

각 컬럼의 dtype 확인 (object, int64, float64)

결측치 비율 컬럼별 체크 (missing ratio heatmap)

타겟 변수 분포 확인 (클래스 불균형 여부)

시술 유형(#04) 분포 확인 (IVF vs DI 비율)

나이 분포 확인 (주요 예측 변수)

중복 row 체크

Phase 2. 기본 전처리

문자열 숫자 변환: '0회'~'6회 이상' → 정수 + is_censored

불임 원인 7개 컬럼 → boolean (True/False → 1/0)

시술유형 #04 → 카테고리 인코딩 (IVF/DI)

특정시술유형 #05 → 희귀값 통합 또는 피처 분해

배란 유도 유형 #07 → 희귀값 통합 → boolean

착상 전 유전 검사/진단 → NaN=0으로 변환

배아 생성 주요 이유 #28 → 5개 multi-hot flag 분해

경과일 컬럼들 → 이상치(음수, 너무 큰 값) 체크

논리 제약 위반 행 탐지 (e.g., 이식 > 생성)

Phase 3. 핵심 파생변수 생성

ever_delivered = 총 출산 > 0 (최강 긍정)

repeated_3plus = 총 시술 >= 3 (반복 실패)

is_first_attempt = 총 시술 == 0 (첫 시도)

prev_birth_rate = 총 출산 / (총 임신 + 1)

is_FET = 해동 배아 수 > 0 (주기 구분)

is_ICSI = 미세주입 난자 > 0

eset_blast = 단일 이식 & 배반포 이식

intended_multi_actual_single = 중간 탈락 케이스

원인_주체 플래그 (남성/여성/양측)

배아 전환율 = 총 생성 배아 / (수집 난자 + 1)

이식_취소 = 이식 배아 수 == 0 (강한 부정)

is_기증정자 = 기증자 정자 혼합 > 0

나이 × 시술 횟수 상호작용

원인 × 시술 매칭 점수

Phase 4. 검증 및 마무리

각 파생변수의 분포 확인 (극단적 편중 없는지)
타겟과의 상관 확인 (너무 높으면 leakage 의심)
K-Fold CV로 베이스라인 AUC 측정
피처 추가 전후 CV 점수 비교 (실제 개선 여부)
SHAP / Feature Importance로 기여도 확인
Train/Test 분포 일치 체크 (covariate shift)
희귀 카테고리 처리 일관성 (train/test 동일)
모델 저장 + 재현 가능한 파이프라인 구축

반드시 피해야 할 실수들

Target Leakage 주의

임신 결과나 이번 시술 이후 정보를 피처에 쓰면 안 됩니다. 예: 이번 시술의 hCG 수치, 이식 후 호르몬 변화 등은 타겟과 직접 연결. '과거 이력'인지 '현재 결과'인지 꼭 확인하세요.

희귀 카테고리 오버피팅

건수 10건 미만의 카테고리를 그대로 one-hot하면 학습 데이터에만 맞춰진 피처가 돼요. 카디널리티 큰 컬럼은 target encoding 또는 희귀값 통합 필수.

censored 값 무시

'6회 이상'을 6으로만 변환하고 flag 안 만들면 환자 A(6회)와 B(12회)가 같아져요. 반드시 is_censored 동반.

비율 계산 시 0 나눗셈

분모에 +1 스무딩을 빼먹으면 NaN 또는 inf 발생. 특히 임신 횟수 0인 환자에서 문제.

NaN의 의미 무시

결측이 '정보 없음'이 아니라 '해당 없음'(DI 환자의 배아 컬럼 등)인 경우가 많아요. 선부른 imputation 금지. 구조적 결측을 먼저 파악.

파생변수 과다 생성

원본 + 파생변수 조합 수가 수백 개가 되면 '의미 있는 피처'가 묻혀요. 적절한 피처 선택(RFE, SHAP 기반)으로 50~100개로 정리.

발표용 스토리 아이디어

성능만큼 중요한 게 **스토리텔링**이에요. 같은 모델이라도 '왜 이 피처를 만들었는가'를 설득력 있게 설명하면 점수가 올라갑니다. 의료 데이터 대회에서 특히 강조되는 부분이에요.

스토리 1. 배아 파이프라인 추적

메시지: '단순 개수가 아닌 감소 패턴에서 환자의 예후를 읽어낸다'

발표 예시 문구

"IVF는 '난자 → 수정 → 배아 → 이식'의 파이프라인입니다. 각 단계에서 개수가 줄어드는 패턴을 분석하여 환자의 생리학적 특성을 포착했습니다. 예를 들어 '수정→배아' 전환율이 30% 미만인 환자 그룹은 평균보다 성공률이 15%p 낮았습니다. 이런 파이프라인 효율성 피처 5개를 추가하여 AUC가 0.XX에서 0.YY로 개선되었습니다."

스토리 2. 원인-시술 매칭 분석

메시지: '의학적으로 적절한 시술을 받은 환자가 더 잘 성공한다'

발표 예시 문구

"남성 요인 불임 환자에게는 ICSI가, 여성 배란 장애에는 배란 유도가 적합합니다. '원인-시술 매칭 점수' 피처를 설계하여 의학적 적절성을 수치화했습니다. 매칭 점수가 높은 그룹의 성공률이 평균보다 유의미하게 높아 임상 의사결정의 중요성을 데이터로 검증했습니다."

스토리 3. 의학 문헌 기반 피처

메시지: '수십 년 검증된 예측 변수를 체계적으로 모델에 통합'

발표 예시 문구

"Templeton 1996, Kawwass 2013, Barnett-Itzhaki 2020 등 주요 논문에서 반복적으로 확인된 예측 변수들을 체계적으로 피처화했습니다. 특히 '과거 출산 경험(ever_delivered)'은 최강의 긍정 신호로, 단독으로도 기저 성공률 26%를 35%까지 올렸습니다. 문헌 기반 접근으로 의료진이 신뢰할 수 있는 해석 가능 모델을 구축했습니다."

스토리 4. 숨은 구조 신호 포착

메시지: '결측과 특이값도 중요한 정보다'

발표 예시 문구

"배란 유도 유형이 비어있는 19만 건은 누락이 아니라 'FET 사이클'을 의미합니다. 이 구조적 결측을 is_FET 플래그로 전환하여 주기 타입을 구분했습니다. FET와 Fresh 사이클은 완전히 다른 프로토콜로, 이 분리만으로 모델 해석력과 성능이 크게 개선되었습니다. '결측에 이유가 있다'는 원칙으로 총 N개의 구조 신호 피처를 발굴했습니다."

스토리 5. 겉보기 같지만 의미 다른 케이스

메시지: '단순 숫자 뒤의 맥락을 피처로 분리한다'

발표 예시 문구

"'배아 1개 이식' 그룹에는 상반된 두 케이스가 섞여 있었습니다. (1) 처음부터 1개만 계획한 양질 배아 케이스(eSET) — 성공률 40%, (2) 여러 개 계획이었지만 배양 중 탈락한 케이스 — 성공률 12%. 같은 '1개 이식'이지만 예후는 정반대. 이 차이를 포착하는 파생변수로 모델의 예측 정확도를 개선했습니다."

발표 전략 팁

서론: 왜 난임 예측이 중요한가

한국 저출산 문제, 시술 비용(1회 300만원+), 정신적 스트레스 등 사회적 맥락을 짧게 언급하면 공감대 형성

본론: 도메인 지식 → 피처

각 피처마다 '의학적 근거 → 데이터 구현 → 성능 기여'의 3단 구조로 설명

차별화: 숨겨진 신호 발굴

누구나 쓰는 피처 말고, 우리 팀만의 통찰 강조 (예: 기증 방향성, 배아 파이프라인, 원인-시술 매칭)

결론: 실무 활용 가능성

'의료진 의사결정 보조', '환자 상담 시 예후 제시' 등 실제 활용 시나리오 제시로 마무리

최종 요약: 기억할 10가지

이 가이드북의 모든 내용을 10가지 핵심으로 압축했습니다. 프로젝트 중 길을 잃을 때 여기로 돌아오세요.

1. 시술 7단계를 머리에 그려라

배란유도 → 채취 → 수정 → 배양 → 이식 → 착상 → 확인. 모든 컬럼이 이 중 어디에 속하는지 파악하면 이해가 빨라요.

2. ever_delivered가 최강 피처

과거 출산 경험은 가장 강력한 긍정 신호. 이 피처 하나만 잘 써도 기본 모델 성능이 크게 오릅니다.

3. is_FET은 반드시 만들어라

해동 배아 > 0은 '동결 주기'를 의미하며, 이 구분이 다른 모든 피처의 해석에 영향을 줘요. Top 5 중요 피처.

4. censored 값은 flag와 함께

'6회 이상'을 6으로만 변환하면 정보 손실. is_censored 플래그를 항상 동반하세요.

5. NaN에는 이유가 있다

결측을 무조건 채우지 말고, 구조적 결측(DI 환자의 배아 컬럼 등)은 '해당없음' 카테고리로 명시적으로 다루세요.

6. 원인×시술 매칭이 차별화

남성 요인 + ICSI, 여성 배란 장애 + 배란 유도 등 의학적 매칭을 피처로 만들면 도메인 지식이 드러나요.

7. 배아 파이프라인 전환율

단순 개수보다 '채취→수정→배아' 전환율이 환자 예후를 더 잘 반영. 비율 피처 여러 개 만들어주세요.

8. 나이는 비선형

나이는 최강 예측 변수지만 선형적이지 않아요. 구간화와 다른 변수와의 상호작용으로 표현하세요.

9. 논리 제약 검증 필수

'이식 + 저장 $\leq$ 총 생성', '미세주입 배아 $\leq$ 미세주입 난자' 등 제약 위반 행이 있는지 확인은 데이터 품질의 기본.

10. 스토리가 성능을 빛낸다

숫자 개선만큼 '왜 이 피처인가'의 서사가 중요해요. 의학 문헌, 임상 직관, 숨은 구조 - 이야깃거리를 만드세요.

팀에게 보내는 메시지

도메인 지식이 부족하다고 불리한 게 아니에요.
오히려 **외부인의 시선**이 숨은 패턴을 잘 찾아냅니다.

이 가이드는 '의학을 배우는 것'이 아니라
'**의학적 맥락에서 데이터를 읽는 법**'을 알려드리는 것입니다.

모든 피처에는 배경이 있고, 모든 결측에는 이유가 있고,
모든 극단값에는 사연이 있어요.

데이터가 말하는 소리를 들어주세요.
여러분이 '왜?'를 던질 때마다 상위권에 가까워집니다.

Good luck!