

8조 팔로리안 v9 모델 가이드북

v3 베이스라인에서 2등 LB까지
의사결정과 검증의 여정

Public LB 0.7422061 · 2등 달성

이 문서는 다음을 다룹니다

- 5분 만에 보는 v3 → v9 개선 여정
- 6개 base 모델 각각의 의미와 기여도
- 학습시킨 도메인 지식과 그 효과
- 왜 CatBoost가 LB를 움직였는가
- Data Leakage 방지 — 모든 단계 점검
- 실패한 시도들에서 배운 것
- 다음에 시도할 개선 카드 (솔직한 기대 효과)

대회: Dacon 초격차 AI 헬스케어 3기 해커톤

태스크: 난임 환자 임신 성공 여부 예측 (ROC-AUC)

최종 제출: 8조_팔로리안_난임프로젝트_v9.csv

목차

Chapter 0	5분 만에 보는 v9 — v3에서 2등까지	p.3
Chapter 1	6개 Base 모델 완전 정복	p.6
Chapter 2	학습시킨 도메인 지식 — 가이드를 어떻게 모델에 녹였나	p.13
Chapter 3	6-way 앙상블 — 왜 CatBoost가 핵심인가	p.16
Chapter 4	Data Leakage 방지 — 모든 단계 점검	p.18
Chapter 5	실패한 시도들 — 왜 폐기했나	p.20
Chapter 6	다음에 시도할 개선 카드	p.22

이 문서 읽는 법

각 모델 설명은 다음 4가지 관점으로 구성됐어요:

-  **무엇인가** 모델의 정체성과 알고리즘 핵심
-  **왜 만들었나** 이 모델을 추가한 의사결정 이유
-  **어떻게 학습** 하이퍼파라미터와 학습 흐름
-  **기여도** 단독 OOF + 앙상블 가중치

5분 만에 보는 v9 — v3에서 2등까지

여러분이 가장 먼저 알아야 할 것: 이 모델이 어디서 시작해서 어디로 갔는지. 단순 결과 나열이 아니라 의사결정의 흐름이에요.

0.1 LB 점수 진화

제출	모델	OOF	LB	등수	평가
AH_03_신정호_v3	LGBM 단일 (94)	0.74045	0.74201	3등	검증된 베이스
8조_팔로리안_v6	LGBM (123, 가이드 +29)	0.74039	0.74188	-	떨어짐
8조_팔로리안_v8	LGBM + Target Encoding	0.74047	0.74210	-	미미
8조_팔로리안_v9	6-way 앙상블 + CatBoost	0.74100	0.74221	2등	★ 최종

v3 (0.74201, 3등)

|

└ v6 (0.74188) ✖ 가이드 +29 추가하니 떨어짐 (-0.00013)

└ v8 (0.74210) ● Target Encoding으로 미세 개선 (+0.00009)

└ v9 (0.74221) ★ 6-way + CatBoost로 의미 있는 개선 (+0.00019, 2등)

0.2 OOF-LB 전이율 — 의사결정의 핵심 신호

OOF가 올라가면 LB도 올라갈까? 답은 "꼭 그렇진 않다"입니다.

변화	OOF Δ	LB Δ	해석
v3 → v6	-0.00006	-0.00013	둘 다 마이너스 (실패)
v3 → v8	+0.00002	+0.00009	OOF 거의 그대로, LB 약간 ↑
v3 → v9	+0.00055	+0.00019	다양성이 진짜 추가될 때만 LB 움직임

💡 핵심 발견

OOF가 살짝 올라간다고 LB가 따라오는 게 아닙니다. **모델 다양성이 진짜 추가될 때만** LB가 의미 있게 움직여요. v9에서 CatBoost를 추가한 순간 비로소 LB가 +0.00019 만큼 안정적으로 상승했습니다.

0.3 v9는 어떻게 만들어졌나 (전체 흐름)

[시작] v3 LB 0.74201, 3등

|
| Q1: 어떻게 점수를 올릴까?
| → 도메인 가이드의 29개 피쳐 추가가 가장 직관적



[v6 시도] 가이드 피쳐 +29개 추가 (123 features) → LB 0.74188 ❌
| 학습: "트리 모델에 도메인 피쳐는 거의 무의미 (가이드 Part 07도 명시)"



[방향 전환] 피쳐 → 모델 다양성으로
| Q2: XGBoost 추가하면 다른 신호 잡을까?
| → 분석: LGBM ↔ XGB 상관 0.9964 (같은 패밀리, 비슷한 실수)



[v8 시도] Target Encoding 3개 추가 → LB 0.74210 ● (미미한 ↑)
| 학습: "TE도 트리 native categorical과 정보 중복"



[가설 검증] 진짜 다른 알고리즘이 필요 = CatBoost
| → Oblivious tree + Ordered TS 시도
| → 단독 OOF는 v3와 동일하지만 다른 모델과 상관 0.991~0.993 (낮음!)



[v9 = 6-way 앙상블] 모든 자산 결합 ★
결과: OOF 0.74100, LB 0.74221 (+0.00019, 등수 3등 → 2등)

0.4 v9의 6개 Base 모델 한눈에

#	모델	피쳐	OOF	가중치	역할
①	LGBM v3	94	0.74045	0.000	v8을 통해 정보 들어감
②	LGBM v8 (TE)	97	0.74047	0.211	TE 신호 + v3 정보
③	XGB v3-feat	94	0.74048	0.035	미미한 기여
④	XGB v6	123	0.74052	0.258	가이드 피쳐 + XGBoost
⑤	분리 모델	94	0.74025	0.103	이식/비이식 구분 학습
⑥	CatBoost ★	94	0.74045	0.392	진짜 다양성의 핵심

6개 Base 모델 완전 정복

각 모델을 4가지 관점(📌 무엇인가 / 😞 왜 만들었나 / ⚡ 어떻게 학습 / 📊 기여도)으로 짚어볼게요.

1.1 모델 ① — LightGBM v3

📌 무엇인가 LightGBM 단일 모델. 94개 피처 (원본 65 + 수치 변환 3 + 토큰 6+4 + 비율 8 + 결측 3 + v3 도메인 5). 5-seed × 5-fold = 25 fold 배깅.

😞 왜 만들었나 이미 LB 0.74201로 검증된 베이스. 새로운 시도가 실패해도 돌아갈 안전망. 가이드 29개 파생변수 중 임상적으로 가장 중요한 5개만 선별 (자세한 이유는 Chapter 2).

⚡ 어떻게 학습 learning_rate=0.025, num_leaves=95, min_data_in_leaf=150, feature_fraction=0.8, bagging_fraction=0.85. early_stopping=120. 약 14분 학습.

📊 기여도 단독 OOF 0.74045. 6-way 앙상블에서 가중치 0.000 (LGBM v8이 v3 + TE라서 v3 정보가 v8에 흡수됨).

1.2 모델 ② — LightGBM v8 + Target Encoding

📌 무엇인가 LGBM v3 + TE 3개 피처 = 97 features. TE 대상은 특정 시술 유형 (24범주), 시술유형 × 나이, 시술유형 × 시기 조합.

😞 왜 만들었나 범주형 컬럼의 그룹별 평균 성공률을 피처화하면 도움될 것이라 가설. v6 가이드 피처 추가가 실패하니 다른 방향 시도.

⚡ 어떻게 학습 Fold 내 OOF 방식: 각 fold의 train fold에서만 평균 계산 → validation fold 적용 → test에는 fold별 평균. smoothing=25~30으로 희귀 카테고리 안정화.

📊 기여도 단독 OOF 0.74047 (v3 대비 +0.00002, 거의 노이즈). LB 0.74210 (+0.00009). 앙상블 weight 0.211.

⚠ Target Encoding이 미미한 이유

LightGBM은 이미 `pd.Categorical` native 처리로 같은 정보를 학습하고 있습니다. TE가 `feature importance` 상위에 강하게 등장 해도(gain 7549, 6497, 3807), 정보 중복일 뿐.

1.3 모델 ③ — XGBoost v3-feat

무엇인가

v3와 같은 94 features, 다른 알고리즘 (level-wise vs leaf-wise). 3-seed × 5-fold.

왜 만들었나

LightGBM과 다른 트리 알고리즘으로 다양성 추가. v6 피쳐 효과는 의심스럽지만 v3 피쳐는 검증됐으니, 같은 피쳐로 알고리즘만 바꿔본 것.

어떻게 학습

learning_rate=0.03, max_depth=7, min_child_weight=10, tree_method=hist. enable_categorical=True로 LGBM과 동일한 범주형 처리.

기여도

단독 OOF 0.74048. 그러나 LGBM v3과 상관 0.9968 (거의 같은 모델). 앙상블 weight 0.035.

1.4 모델 ④ — XGBoost v6 (가이드 +29 피쳐)

무엇인가

XGBoost + 가이드 추가 29개 피쳐 = 123 features. `시술적합성`, `배아수_그룹`, `ICSI_난자_구간` 같은 범주형 추가.

왜 만들었나

LGBM v6은 LB에서 떨어졌지만, XGBoost는 다른 알고리즘이라 가이드 피쳐를 다르게 활용할 수도. 결과: 단독 OOF 0.74052로 가장 높았음.

어떻게 학습

LGBM과 같은 핵심 하이퍼파라미터, enable_categorical=True. 3-seed × 5-fold.

기여도

단독 OOF 0.74052 (가장 높음). 앙상블 weight 0.258. 가이드 피쳐가 XGBoost에서는 약간 작동.

1.5 모델 ⑤ — 분리 모델 (이식 vs 비이식)

무엇인가

이식 여부에 따라 두 그룹으로 나누어 LightGBM 따로 학습. 결과를 합쳐 단일 OOF.

왜 만들었나

데이터 분포 분석:

- 이식 안 함 (16.71%): 성공률 1.96% (거의 다 실패)

- 이식 함 (83.29%): 성공률 **30.62%**

격차 28%p이어서 분리 학습이 효과적일 거라 가설.

🔗 어떻게 학습

그룹별로 다른 min_data_in_leaf (NoTransfer=100, Transfer=200). v3 피쳐 사용. 5-seed × 5-fold.

📊 기여도

단독 OOF **0.74025** (가장 낮음, -0.00020). 데이터 분리로 정보 손실. **그러나 다른 패턴을 잡아서 다양성 기여**. 앙상블 weight 0.103.

1.6 모델 ⑥ — CatBoost ★ (핵심 다양성)

📌 무엇인가

Oblivious tree (완전 대칭 트리) + Ordered Target Statistics. v3와 같은 94 features.

😞 왜 만들었나

LGBM ↔ XGBoost 상관 0.9964 (같은 패밀리, 비슷한 실수). **진짜 다른 알고리즘이 필요**. CatBoost는 알고리즘 자체가 달라서 다른 종류의 실수 패턴을 가짐.

🔗 어떻게 학습

메모리 안전 설정 (이전 OOM 경험 반영):

- `border_count=64` (256→64로 양자화 줄임)
- `max_ctr_complexity=0` (CTR 비활성화로 메모리 ↓)
- `subsample=0.7, rsm=0.7`
- `depth=6, iterations=600`

3-seed × 5-fold. 약 28분 (가장 오래 걸림).

📊 기여도

단독 OOF 0.74045 (v3와 동일). **그러나 다른 모델과 상관 0.9916~0.9932** (이전 모델들 0.99~0.998 대비 확연히 낮음). 앙상블 weight **0.392** (가장 큼). **v9 LB 상승의 진짜 원동력**.

🎯 CatBoost가 핵심인 이유 — 알고리즘 비교

알고리즘	트리 구조	분기 결정	Categorical 처리
LightGBM	Leaf-wise (비대칭)	Histogram	정수 매핑
XGBoost	Level-wise (대칭)	Histogram	원-핫 또는 정수
CatBoost	Oblivious tree (완전 대칭)	Ordered statistics	Ordered TS

같은 점수의 모델이라도 알고리즘이 다르면 **"다른 행을 다르게 예측"** 합니다. 이것이 앙상블에서 진짜 다양성을 만드는 원천.

학습시킨 도메인 지식 — 가이드를 어떻게 모델에 녹였나

난임 도메인 가이드의 모든 임상 지식을 어떻게 피처와 모델 설계에 반영했는지 정리합니다.

2.1 IVF 7단계를 모델이 학습하도록

STEP 01: 배란 유도	[컬럼] 배란 유도 유형
▼	
STEP 02: 난자 채취	[컬럼] 수집된 신선 난자 수, 난자 채취 경과일
▼	
STEP 03: 정자 준비	[컬럼] 정자 출처
▼	
STEP 04: 수정 (IVF/ICSI)	[컬럼] 혼합된 난자 수, 미세주입된 난자 수
▼	
STEP 05: 배양	[컬럼] 총 생성 배아 수
▼	
STEP 06: 이식 또는 동결	[컬럼] 이식된 배아 수, 저장된 배아 수
▼	
STEP 07: 착상 및 확인	[TARGET] 임신 성공 여부

이 7단계의 모든 컬럼을 원본 그대로 모델에 넣었습니다. 트리 모델은 단계 사이의 관계를 자동으로 학습해요.

2.2 가이드 29개 파생변수 vs v3 채택 5개

가이드의 29개 파생변수 중 v3는 **5개만 채택**. 이 결정이 핵심이었습니다.

채택 5개 (v3)	한국어 의미	채택 이유
<code>real_age_num</code>	실제 난자 제공자 나이	임신 성공의 가장 강한 변수, 자가/기증 분기 (트리 자동 못 함)
<code>days_mix_to_transfer</code>	배아 배양 기간	3일(분할기) vs 5일(배반포) — 임상 결정
<code>log_n_embryo</code>	배아 수의 로그 변환	한계효용 체감, 트리는 비선형 변환 못 함
<code>miss_gene_test</code>	유전검사 결측 통합	결측 패턴이 클리닉 정책 시그널
<code>age_x_embryo_ratio</code>	나이 × 이식을 상호작용	고령일수록 이식 개수 늘림

보류한 24개의 공통 이유

난임 도메인 가이드 Part 07이 직접 명시:

"최대 성능 추구 (XGBoost/LightGBM): 원본만 써도 충분 ($D \approx A$, 트리는 상호작용 자동 학습)"

가이드 자체 실험: Model A (원본) AUC 0.58600 vs Model D (원본+파생) AUC 0.58613 → 차이 **+0.013%p** (거의 0). v6에서 직접 검증 결과 OOF -0.00006, LB -0.00013으로 떨어짐.

2.3 가이드 핵심 통찰 — 4가지를 어떻게 반영했나

① 배아 수 역U자 패턴 (총 생성 배아 수)

가이드 분석:

- 7개 미만: 22.07% 성공률 (고령 + 저반응)
- 7~20개: **35.03%** 성공률 ← 최적
- 20개 초과: 22.64% (PCOS + 과반응)

→ 모델 반영: `log_n_embryo` 로 비선형 변환. v6에선 `배아수_그룹` 4범주화도 시도.

② `ever_delivered` = 가장 강한 단일 예측 변수

"과거에 출산했다는 건 임신과 출산이 가능한 몸의 증명" (Templeton 1996, Barnett-Itzhaki 2020)

→ 모델 반영: v6에서 `ever_delivered = 총 출산 횟수 > 0` 추가.

③ `is_FET` — Top 5 중요 피쳐

동결 vs 신선 주기는 거의 모든 다른 컬럼의 해석을 바꿈.

→ 모델 반영: 원본 `해동된 배아 수` 로 이미 학습. v6에선 `is_FET = 해동 > 0` 명시 추가.

④ 남성요인 × ICSI 적합성

남성요인	ICSI 사용	적합성
✓	✓	AdequateICSI (적절)
✗	✓	OverusedICSI (과사용)
✓	✗	UnderservedICSI (필요한데 안함)
✗	✗	Neither

→ 모델 반영: v6에서 `기술적합성` 4범주 피쳐.

2.4 연령별 성공률 — 가장 강한 단일 변수

연령대	난자 질	IVF 성공률	모델 반영
20대~34세	최상	35~45%	<code>age_num</code> = 26
35~37세	양호	30~35%	<code>age_num</code> = 36
38~40세	감소	20~25%	<code>age_num</code> = 38.5
41~42세	빠른 감소	10~15%	<code>age_num</code> = 41
43세 이상	심각한 감소	5% 이하	<code>real_age_num</code> 핵심

43세 이상 자가시술 환자는 거의 실패. **기증 난자로 회피하는 패턴**을 `real_age_num` 으로 포착.

6-way 앙상블 — 왜 CatBoost가 핵심인가

3.1 가중치 결정 과정

scipy.optimize Nelder-Mead로 OOF에서만 가중치 탐색. **test 데이터는 절대 안 봄** (Data Leakage 방지).

```
def neg_auc(w):
    w = np.clip(w, 0, None) / max(w.sum(), 1e-9)
    return -roc_auc_score(y, oof_array @ w)

# 5개 다른 시작점에서 robust optimum 확인
starts = [
    [0.0, 0.31, 0.165, 0.387, 0.138, 0.0],
    [0.0, 0.25, 0.15, 0.30, 0.10, 0.20],
    [0.0, 0.20, 0.15, 0.25, 0.10, 0.30],
    [0.1, 0.20, 0.15, 0.25, 0.10, 0.20],
    [1/6]*6,
]

# 모든 시작점이 OOF 0.74100 근처로 수렴 → robust optimum 확인
```

3.2 최적 가중치 — 왜 이런 값?

모델	가중치	이유
LGBM v3	0.000	v8(=v3+TE)을 통해 v3 정보가 흡수됨
LGBM v8 (TE)	0.211	TE 신호 + v3 정보 보존
XGB v3-feat	0.035	미미 (v3와 상관 0.9968)
XGB v6	0.258	가이드 피처를 XGBoost에서 살려냄
분리 모델	0.103	약하지만 다른 패턴 → 다양성 기여
CatBoost	0.392	진짜 다른 알고리즘 → 가장 큰 가중치

3.3 CatBoost가 다양성을 만드는 증거 — 상관 분석

같은 OOF 점수여도 **상관이 낮으면 진짜 다양성**입니다.

모델 쌍	OOF 상관	다양성
LGBM v3 ↔ XGB v6	0.9964	낮음 (같은 트리 패밀리)

LGBM v3 ↔ XGB v3f	0.9968	낮음
XGB v6 ↔ XGB v3f	0.9982	매우 낮음 (둘 다 XGB)
CatBoost ↔ LGBM v3	0.9928	높음 ✓
CatBoost ↔ LGBM v8	0.9925	높음 ✓
CatBoost ↔ XGB v3f	0.9932	높음 ✓
CatBoost ↔ 분리 모델	0.9916	높음 ✓

🎯 핵심 결론

CatBoost는 단독 OOF는 v3와 동일(0.74045) 하지만, 다른 모델들과 상관이 모두 0.991~0.993입니다. 이전 모델들끼리 0.99~0.998이었던 것과 비교하면 **확연히 낮음**.

→ "같은 점수의 모델이지만 다른 행을 다르게 예측" → 앙상블에서 상호 보완 → LB 실제 상승.

3.4 결과 종합

단계	OOF	LB	v3 대비
v3 단독	0.74045	0.74201	(베이스)
5-way (CatBoost 없이)	0.74077	(미제출)	OOF +0.00032
v9 = 6-way (CatBoost 추가)	0.74100	0.74221	OOF +0.00055, LB +0.00019

CatBoost 추가가 **OOF +0.00023, LB +0.00020** 만큼 추가 기여.

Data Leakage 방지 — 모든 단계 점검

대회 규정: label encoding, get_dummies, scaling, 결측 처리에 test 사용 금지. 모든 단계에서 점검했습니다.

4.1 점검 매트릭스

항목	위반 위험	우리의 방어
범주형 매핑	<code>pd.get_dummies(pd.concat([train, test]))</code>	train의 unique 값만 cat_maps 저장. test에 transform만. unseen → NaN
결측 대치	<code>train+test</code> 평균으로 fillna	결측 대치 안 함. 트리 native NaN 처리
Scaling	<code>StandardScaler.fit(train+test)</code>	트리 모델은 scaling 불필요
Target Encoding	<code>train</code> 전체로 mapping 후 test 적용	Fold 내 train fold만으로 평균. test는 fold별 평균
CV 분할	test를 CV에 포함	StratifiedKFold(train만)
양상블 가중치	test로 가중치 튜닝	OOF에서만 scipy.optimize

4.2 안전한 범주형 처리 — 코드 예시

```
# ✅ 안전 - train에서만 카테고리 수집
cat_maps = {}
for c in cat_cols:
    train[c] = train[c].astype(str).replace({'nan': np.nan})
    vals = sorted(train[c].dropna().unique()) # train 내부에서만
    cat_maps[c] = vals
    train[c] = pd.Categorical(train[c], categories=vals)

# ✅ 안전 - test에는 train의 카테고리만 적용
for c in cat_cols:
    test[c] = test[c].astype(str).replace({'nan': np.nan})
    vals = cat_maps[c] # train의 카테고리 재사용
    unseen = (~test[c].isin(vals)) & test[c].notna()
    if unseen.any():
        test.loc[unseen, c] = np.nan # 새 값은 결측으로 (누수 방지!)
    test[c] = pd.Categorical(test[c], categories=vals)
```

4.3 Target Encoding 누수 방지

```
# ✅ Fold 내 OOF 방식
for fold, (tr_idx, va_idx) in enumerate(skf.split(train, y)):
    # train fold에서만 mapping 계산
    mapping = build_mapping(train.iloc[tr_idx], y[tr_idx], smoothing=25)
    # validation fold에 적용 (자기 정답 안 봄)
    oof[va_idx] = train.iloc[va_idx].map(mapping)
    # test에는 fold별 mapping의 평균 누적
    test_pred += test.map(mapping) / n_folds
```

스모크 테스트: 같은 카테고리 내 OOF TE std = 0.00841 (> 0). 만약 누수면 std=0이어야 함. → 누수 없음 확인.

4.4 자동 패턴 스캔 결과

모든 학습 코드에 대해 `grep` 패턴 검색 — 0건 위반:

패턴	매치
<code>pd.concat(\[train.*test\]</code>	0건 ✓
<code>get_dummies.*pd.concat</code>	0건 ✓
<code>LabelEncoder(\)\.fit\(.test</code>	0건 ✓
<code>MinMaxScaler(\)\.fit\(.test</code>	0건 ✓
<code>StandardScaler(\)\.fit\(.test</code>	0건 ✓

실패한 시도들 — 왜 폐기했나

v9 도달 전 시도하고 폐기한 것들. 실패한 시도에서도 다음 결정에 영향을 준 학습이 있었습니다.

5.1 v6: 가이드 피처 +29 (제출함, LB 떨어짐)

결과: OOF -0.00006, LB -0.00013

왜 실패: Feature importance 분석 결과 추가 24개 피처 중 상위 20위 안에 든 건 **2개뿐** (성숙률 13위, age_x_log_embryo 16위). 가이드 본인이 Part 07에서 "트리는 상호작용 자동 학습" 명시.

학습: GBM에 도메인 피처 추가는 신중. 트리는 이미 단순 비율을 자동 학습.

5.2 3-way 앙상블 (LGBM v3 + XGB v3f + XGB v6, 미제출)

결과: OOF +0.00027, but LB 미제출

왜 미제출: LGBM ↔ XGBoost 상관 0.9964 (같은 패밀리). OOF는 올랐지만 LB 못 움직일 가능성 큼 → 제출 한도 보호 위해 미제출.

학습: 진짜 다른 알고리즘이 필요. → CatBoost 시도의 동기.

5.3 분리 모델 단독 (실패, 앙상블에 흡수)

결과: OOF -0.00020 (단독은 약함)

왜 실패: 데이터 분리로 각 그룹의 정보 손실. NoTransfer 그룹 v3 0.94183 → split 0.93909.

학습: 단독은 약하지만 **다양성 자산으로 활용 가능**. → 6-way에 weight 10.3%로 포함.

5.4 Sample Weight (고령 환자 가중치, 미제출)

결과: OOF -0.00224 (큰 추락)

가설: 오류 분석에서 상위 오류 2000건 중 46% (926건)이 고령(40+) 환자 성공 케이스. 가중치 1.7로 강조.

왜 실패: 고령 그룹 AUC는 0.76617로 향상되었지만, 다른 그룹 학습 방해로 전체 떨어짐. weight 1.7이 너무 강함.

학습: 강한 weight는 trade-off 큼.

5.5 Stacking (Level-2 Meta Learner, 미제출)

결과: OOF -0.012 (매우 큰 추락)

왜 실패: Base 모델은 5-seed × 5-fold split A로 OOF 만들었는데, meta learner는 다른 split B로 학습 → fold 경계 불일치 → meta가 OOF를 "정답에 가까운 신호"로 오인 → overfitting.

학습: 정확한 stacking은 모든 layer가 같은 fold split 공유 필요. 시간 부족으로 폐기.

5.6 학습 요약

실패 시도	다음 단계 결정에 준 학습
v6 가이드 +29	트리에 도메인 피쳐는 무의미 → 알고리즘 다양성으로 전환
3-way 앙상블	XGBoost는 같은 패밀리 → 진짜 다른 알고리즘(CatBoost) 필요
분리 모델	단독은 약함, 앙상블 자산으로만 활용
Sample weight	강한 weight는 trade-off 큼
Stacking	fold split 일관성 중요, 가중평균 유지

다음에 시도할 개선 카드

v9가 끝이 아닙니다. 더 점수를 올리고 싶다면 시도해볼 만한 카드들 — 솔직한 기대 효과와 위험도 함께 적습니다.

6.1 단기 카드 (1~3시간 내)

카드	설명	기대 OOF Δ	시간	위험
CatBoost 5-seed로 늘림	현재 3-seed → 5-seed로 배깅 안정화	+0.00003~0.00007	~35분	거의 없음
LightGBM dart boosting 추가	트리 dropout 방식 → 다른 학습 패턴	+0.0001~0.0003	~1시간	시간 큰 데 비해 효과 미지수
10-fold CV로 OOF 안정화	5-fold → 10-fold (분산 ↓)	OOF 비슷, LB 안정성 ↑	~2시간	거의 없음
HistGradientBoosting 추가	scikit-learn 내장 GBM	+0.00005~0.0001	~30분	거의 없음

6.2 중기 카드 (반나절~하루)

카드	설명	기대 효과	위험
정확한 Stacking	모든 layer가 같은 fold split 공유 보장	OOF +0.0005~0.002 (가능)	구현 복잡, 디버깅 필요
Pseudo-labeling	매우 confident한 test (>0.9 또는 <0.05)를 train에 추가	LB +0.001~0.003 (가능)	자기 예측 overfitting 위험 큼
TabNet 추가	딥러닝 기반 tabular 모델	진짜 다른 패밀리 → 다양성 ↑	시간/메모리 많이 필요, 효과 미지수
FT-Transformer 추가	Transformer 기반 tabular 모델	비슷	비슷

6.3 본질적 개선 카드 (난이도 ↑ ↑)

카드	왜 본질적인가
환자 단위 그룹 인식	

	같은 환자가 여러 행에 있다면, GroupKFold로 누수 방지. 현재는 환자 ID가 없어서 못 함.
시술 시기별 모델 분리	시술 시기 코드 별로 분포가 다를 가능성. 분리 학습 시도 가치.
도메인 의사 자문	데이터에 안 보이는 임상 지식 발견. 코드/모델로는 못 잡는 신호.
AutoGluon 기반 자동 앙상블	모델 풀을 자동 탐색. 사람이 시도 못한 조합 발굴 가능.
External 임상 지식 통합	대회 규정상 외부 데이터 금지지만, public 임상 통계는 검토 가치.

6.4 솔직한 한계 평가

⚠ LB 천장 ~0.7425 추정 (0.75는 본질적으로 어려움)

현재까지 시도들 종합 결과:

- v3 → v9: LB +0.00019 (0.74201 → 0.74221)
- 모든 트리 모델이 비슷한 천장에서 수렴
- OOF 개선이 LB로 35%만 전이됨

한계의 본질적 이유:

1. IVF 성공률 자체가 30~40% 확률 게임 — 본질적 노이즈 천장
2. 예측 가능한 신호는 이미 거의 다 쥐어쥔 상태
3. 0.75 (+0.008)는 단일 카드로 불가능, 누적해도 어려움

6.5 추천 우선순위

다음 시도 한다면 이 순서를 추천:

1. **CatBoost 5-seed** — 안전한 미세 개선 (+0.00003~0.00007)
2. **HistGradientBoosting 추가** — 또 다른 알고리즘 패밀리, 빠른 시도
3. **10-fold CV** — LB 안정성 ↑ (제출 점수 분산 줄임)
4. **정확한 Stacking** — 큰 효과 가능, 구현 신중하게
5. **TabNet/FT-Transformer** — 진짜 다른 패밀리, 마지막 카드

🎯 핵심 원칙

v9의 성공 비결을 다음에도 적용하세요:

1. **OOF 개선 ≠ LB 개선** — OOF만 보고 판단하지 말 것
2. **모델 다양성은 알고리즘 패밀리 단위** — 같은 패밀리는 한계
3. **실패한 시도도 학습 자산** — 다음 단계 의사결정에 활용
4. **검증된 베이스 보호** — 안전망을 항상 유지