

8조 팔로리안: 난임 프로젝트 성능 고도화 전략 (v10)

점수 0.75~0.76 이상 달성을 위한 핵심 개선점 및 전처리 코드

1. 3가지 핵심 개선점

1.1 '개수'가 아닌 '전환율' 피처의 도입

현재 코드의 한계: 난자 수, 배아 수 등을 독립된 숫자로 처리. 하지만 의료진은 "나이 대비 배아 생성 효율"을 가장 중요하게 판단합니다.

- 수정 효율: $\#39(\text{총 배아}) / (\#48(\text{채취 난자}) + 1)$
- 이식 효율: $\#42(\text{이식 배아}) / (\#39(\text{총 배아}) + 1)$
- 나이 대비 효율: $(\text{총 생성 배아 수}) / (\text{환자 나이} - \text{최소가임연령})$

* 나이가 많은데 배아 효율이 높다면 매우 강력한 성공 신호입니다.

1.2 '신선 주기'와 '동결 주기'의 분리

46번(해동 배아 수) 컬럼 유무에 따라 데이터의 성격이 완전히 달라집니다.

- 신선 주기: 채취 후 즉시 이식. 호르몬 변화가 크고 신체 부담이 높음.
- 동결 주기(FET): 해동 후 이식. 자궁 환경이 상대적으로 안정적임.

개선 방법: 단순히 `is_FET` 플래그를 추가하는 것을 넘어, 동결 주기 시 무의미한 변수(예: #48 신선 난자 수)를 특수값(-1 등)으로 처리하여 모델의 노이즈를 제거해야 합니다.

1.3 남성 요인과 ICSI의 '정합성' 체크

11번(남성 요인)과 40번(ICSI 시도) 사이의 관계가 결정적인 변별력을 제공합니다.

- `is_mismatch` 지표: 남성 요인이 있는데 ICSI를 미시행했거나, 남성 요인이 없는데 ICSI를 과도하게 시행한 케이스.

2. v10 개선판 전처리 코드

```
import pandas as pd
import numpy as np

def transform_to_v10_pipeline(df):
    # 1. 기초 결측치 처리 (배아/난자 관련 수치는 0으로 처리)
    pipeline_cols = [f'col_{i}' for i in range(39, 53)]
    df[pipeline_cols] = df[pipeline_cols].fillna(0)

    # 2. 논리적 정합성 보정 (Sanity Check)
    # 총 배아 >= 이식 + 저장
    df['col_39'] = np.maximum(df['col_39'], df['col_42'] + df['col_44'])
    # ICSI 배아 <= ICSI 시도 난자
    df['col_41'] = np.minimum(df['col_41'], df['col_40'])

    # 3. [핵심] 단계별 전환율 (Conversion Rates)
    # (1) 수정 효율: 난자 대비 배아 생성 성공률
    df['egg_to_embryo_rate'] = df['col_39'] / (df['col_48'] + 1)
    # (2) ICSI 기술 효율: 직접 주입 대비 수정 성공률
    df['icsi_success_rate'] = df['col_41'] / (df['col_40'] + 1)
    # (3) 배아 품질 지표: 생성 대비 사용(이식/저장) 가능 비율
    df['embryo_utilization_rate'] = (df['col_42'] + df['col_44']) / (df['col_39'] + 1)
    # (4) 전체 프로세스 생산성
    df['total_pipeline_efficiency'] = (df['col_42'] + df['col_44']) / (df['col_48'] + 1)

    # 4. 도메인 전략 플래그
    df['is_FET'] = (df['col_46'] > 0).astype(int)
    df['is_split_strategy'] = ((df['col_50'] > 0) & (df['col_40'] > 0)).astype(int)
    df['is_donor_sperm'] = (df['col_52'] > 0).astype(int)

    # 5. [상급] 나이 가중치 정규화
    df['age_normalized_efficiency'] = df['egg_to_embryo_rate'] * (df['patient_age'] / 35)

    return df
```

3. 성능 향상의 핵심 원리

1. 데이터의 '절대 크기' 문제 해결

난자 20개 중 배아 5개와 난자 5개 중 배아 5개는 완전히 다른 의미입니다. 전환율은 후자를 '고효율/고예후'군으로 즉각 분류합니다.

2. 주기(Cycle)의 성격 분리

신선 주기와 동결 주기를 명확히 구분함으로써 모델이 서로 다른 환경에서의 성공 패턴을 혼동 없이 학습하게 합니다.

3. '이상 신호' 포착

조건과 전략의 불일치(Mismatch)를 수치화하여, "조건이 좋은데 왜 실패했는가"에 대한 논리적 근거를 모델에 제공합니다.