

변수 처리 방안 스크립트 (8조 팔로피안)

변수 처리 방안 — 컬럼별 쉬운 설명 스크립트

이 문서는 69개 컬럼을 하나씩 읽으면서 이해할 수 있도록 쓴 스크립트입니다. 각 컬럼마다 이렇게 구성돼 있어요:

- 이게 뭔가요? (의미)
- 데이터에 어떤 값이 있나요? (분포)
- 우리는 어떻게 처리하나요? (결정)
- 왜 그렇게 하나요? (근거)
- 여기서 파생변수를 만들 수 있어요! (해당 시)

읽는 사람: 팀원 + 처음 보는 사람도 이해 가능하도록 선행 문서: [전처리_계획서.md](#) (v2.2)

시작하기 전에

이 대회가 뭐 하는 건지 다시 확인:

- 한 행(row) = 한 번의 IVF/DI 시술 시도
- 목표: 이 시도가 임신 성공(1)인지 실패(0)인지 예측
- 평가: AUC (확률값 제출)

69개 컬럼을 이제부터 한 번에 하나씩 보겠습니다.

00. ID

이게 뭔가요? 환자 고유 번호. `TRAIN_000000` 처럼 생긴 식별자.

우리는 어떻게 처리하나요? ❌ 학습에서 제외. 제출 파일 만들 때만 사용.

왜 그렇게 하나요? 학번이 시험 점수에 영향을 주지 않듯이, ID 자체는 예측에 아무 정보도 주지 않아요. 그냥 구별용입니다.

01. 시술 시기 코드

이게 뭔가요? 어느 병원/시기에 시술했는지를 나타내는 **익명화된 7자리 코드**. `TRZKPL`, `TRDQAZ` 같은 형태로 7개 유니크 값이 있어요.

데이터에 어떤 값이 있나요? 7개 코드가 각각 34,000~38,000건씩 거의 **균등하게** 분포돼 있어요.

우리는 어떻게 처리하나요? 🟡 Frequency Encoding 적용 → LGBM 학습 → Feature importance 하위 25%면 DROP

왜 그렇게 하나요? HTML 분석은 "익명 코드니까 그냥 버려"라고 했어요. 하지만 Nature Communications 2025 논문이 ***센터별 특화 모델이 전국 통합 모델보다 성능 우수($p < 0.05$)***라고 증명했습니다.

병원마다 숙련도·장비·환자 풀이 다르니 시기 코드가 ***병원 숙련도 프록시***가 될 수 있어요. 그래서 바로 버리지 말고, frequency로 바꿔서 학습 한 번 돌리고 **결과 보고 결정**합니다.

👤 02. 시술 당시 나이

이게 뭔가요? 시술 받은 여성의 나이. 연속 숫자가 아니라 **구간형**이에요.

데이터에 어떤 값이 있나요?

만18-34세:	102,476건 (성공률 32.3%)
만35-37세:	57,780건 (성공률 27.8%)
만38-39세:	39,247건 (성공률 21.7%)
만40-42세:	37,348건 (성공률 15.9%)
만43-44세:	12,253건 (성공률 11.8%)
만45-50세:	6,918건 (성공률 16.8%)
알 수 없음:	329건 (성공률 0.0%) ▲

우리는 어떻게 처리하나요? ✅ Ordinal + Median 병행 생성

```
ord: 0→5까지 숫자 등급
med: 중앙값 (만18-34→26.0, 만35-37→36.0, ...)
알 수 없음 → ord=-1 (sentinel)
```

왜 그렇게 하나요? 이건 이 대회에서 가장 강력한 단일 예측인자입니다 (Templeton 1996, Biomedicines 2025).

왜 2개 버전을 만드냐면:

- **ord**: "1등급 차이"의 순서 정보
- **med**: "나이 5살 차이"라는 거리 정보

모델이 둘 다 보고 더 유용한 걸 쓰게 합니다.

"알 수 없음" 329건은 **성공률 0%**인 매우 특이한 그룹. HTML은 "이걸 3(중앙값)으로 채우자" 했는데, 그러면 **실패 그룹이 평범한 그룹으로 둔갑**해서 정보 소실. 그래서 sentinel **-1** 로 따로 둡니다.

💡 파생변수 힌트:

- **elderly = (나이_ord >= 3)** — 만40세 이상
- **age_median** 자체가 다른 변수와 곱하기 교호작용에 유용

🔄 03. 임신 시도 또는 마지막 임신 경과 연수

이게 뭔가요? 직전 임신(또는 시도) 이후 몇 년이 지났는지. **96.3%가 결측**.

왜 이렇게 결측이 많나요? 첫 시도 환자는 "이전 임신"이 없으니 값이 없는 게 당연해요. 구조적 결측입니다.

우리는 어떻게 처리하나요?  NaN → -1 (sentinel) + `first_attempt` flag 생성

왜 그렇게 하나요? HTML은 "결측 96%라 DROP"이라고 했어요. 하지만 실측 결과:

- NaN 성공률: 26.0% (첫 시도거나 이전 기록 없음)
- 값 있음: 21.7% (이전 임신 경험 있음)

4%p 차이나는 유의한 신호. 더 중요한 건 "첫 시도인지 여부" 그 자체가 정보예요.

💡 파생변수:

- `first_attempt = (총 임신 == 0)` — 더 직접적 신호
- `long_infertility = (임신 경과 연수 >= 7)` — Templeton 1996에서 유의



04. 시술 유형

이게 뭔가요? IVF (체외수정) vs DI (기증 정자 인공수정)의 2가지 대분류.

데이터에 어떤 값이 있나요?

IVF: 250,060건 (성공률 26.2%)
DI: 6,291건 (성공률 12.9%)

우리는 어떻게 처리하나요?  Category 그대로 유지 (LGBM native)

왜 그렇게 하나요? 성공률 자체가 2배 차이. 매우 강한 신호이면서 DI 시술은 배아 관련 컬럼을 전부 안 쓴다는 구조 정보를 포함해요. 이 정보를 기반으로 R1 규칙(시술 유형 == DI → 배아 관련 NaN → 0)이 작동합니다.



05. 특정 시술 유형 ★★★★★ 가장 중요한 컬럼 중 하나

이게 뭔가요? ICSI, IUI 같은 세부 기법. 24개 유니크 값이 있어요. `ICSI:ICSI` 처럼 콜론 포함된 값도 있습니다.

데이터에 어떤 값이 있나요? (상위)

ICSI:	122,368건 (성공률 27.3%)
IVF:	91,755건 (26.1%)
Unknown:	26,939건 (23.7%)
IUI:	6,100건 (12.9%)
ICSI:ICSI:	2,314건 (1.0%) ▲ 반복 시도
ICSI/BLASTOCYST:	1,609건 (35.7%) ↑
IVF/BLASTOCYST:	1,248건 (36.6%) ↑
IVF:IVF:	1,146건 (1.0%) ▲ 반복 시도

우리는 어떻게 처리하나요?  공백 정규화 + 3개 binary flag로 분해

```
has_repeat = ":" 포함      (성공률 26% → 7.8%)
has_blast  = "BLASTOCYST" 포함 (26% → 36.1%)
has_ah     = "AH" 포함      (26% → 20.8%)
```

왜 그렇게 하나요? 24개 카테고리로 뭉쳐 있으면 **신호가 희석**됩니다. 예를 들어 "ICSI / BLASTOCYST"라는 값은 "ICSI였다"는 정보와 "blastocyst 이식"이라는 정보를 동시에 가지는데, 모델은 그걸 하나의 묶음으로만 봐요.

3개 flag로 분해하면:

- 반복 시도 여부 (성공률 1/4로 감소!)
- Blastocyst 여부 (성공률 1.4배 증가)
- AH(부화 보조) 여부 (어려운 케이스 표시)

각각 독립적으로 학습됩니다.

추가 함정: 공백 차이만 있는 중복 표기가 있어요.

```
"ICSI / BLASTOCYST:IVF / BLASTOCYST"      (6건)
"ICSI / BLASTOCYST :IVF / BLASTOCYST"      (4건) ← 콜론 앞 공백만 다름
```

→ `str.replace(r"\s+", "")` 등으로 정규화 필수.

06. 배란 자극 여부

이게 뭔가요? 배란을 유도하기 위해 호르몬 주사를 썼는지 (0/1).

우리는 어떻게 처리하나요? ☒ Int8 유지.

왜 그렇게 하나요? 배란 자극이 필요했다는 건 **자연 배란이 어렵다**는 신호. Toner 1991의 "난소 예비력 저하" 간접 프록시 역할.

07. 배란 유도 유형

이게 뭔가요? 어떤 약물로 자극했는지.

데이터에 어떤 값이 있나요?

```
기록되지 않은 시행:      194,432건
알 수 없음:              61,917건
세트로타이드 (억제제):    1건 ▲
생식선 자극 호르몬:        1건 ▲
```

우리는 어떻게 처리하나요? ☒ 희귀값(각 1건) → "알 수 없음"으로 통합

왜 그렇게 하나요? 건수 1건인 값은 통계적 의미가 없고, test셋엔 아예 없어요. 학습만 혼란스러워집니다. 통합하면 사실상 **2값 ("기록되지 않은 시행", "알 수 없음")**이 되어 단순 boolean처럼 쓸 수 있어요.



08. 단일 배아 이식 여부

이게 뭔가요? 1개 배아만 이식하기로 계획했는가 (0/1). 쌍둥이 위험을 줄이기 위한 현대 권장 방식.

데이터에 어떤 값이 있나요?

0 (다중): 191,677건 (성공률 22.9%)
 1 (단일): 58,383건 (성공률 36.7%) ↑
 NaN: 6,291건 (DI 케이스)

우리는 어떻게 처리하나요? ✅ Int8 유지 + NaN은 중앙값으로 (fold 내부)

왜 그렇게 하나요? 단일 이식이 오히려 성공률 1.6배 높음! 왜 이럴까요?

실제로는 ***양질의 배아 1개를 고를 수 있을 만큼 상태가 좋은 케이스***가 단일 이식을 선택하기 때문. 다중 이식은 "배아 질이 부족해서 여러 개 넣어서 확률 올리자" 전략인 경우가 많아요.

즉 원인과 결과의 역전. 이런 통계적 특이점을 모델이 학습합니다.



핵심 파생변수:

- `eset_blast = (단일 이식 == 1) AND (blastocyst)` — Kawwass 2013에서 최고 조합 (OR 1.17 × 2.32)
- `intended_multi_actual_single = (단일==0) AND (이식==1)` — 의도와 실체가 다른 "중간 탈락" 케이스



09. 착상 전 유전 검사 사용 여부

이게 뭔가요? 배아의 유전적 이상을 착상 전에 검사했는지. 98.9% 결측 (사실상 미시행이 대부분).

우리는 어떻게 처리하나요? ✅ NaN → 0 (미시행), 1은 유지 (시행)

왜 그렇게 하나요? HTML은 "99% 결측이니 DROP"이라 했어요. 하지만 실측:

- 값=1인 케이스 성공률: 14.8%
- NaN 케이스 성공률: 26.0%
- -11%p 차이!

왜 검사받은 사람이 더 실패할까요? 검사가 필요할 만큼 어려운 케이스(고령·반복 실패)만 이 검사를 받기 때문. 즉, 검사 받음 = "힘든 케이스" 마커.

NaN→0 변환하면 1%가 "검사 받음"이라는 좋은 flag가 됩니다.



10. 착상 전 유전 진단 사용 여부

이게 뭔가요? 09번과 비슷한 또 다른 유전 검사.

우리는 어떻게 처리하나요? ✅ Int8 유지 (결측 2.5%만)



11-17. 불임 원인 범주형 (7개)

이게 뭔가요? 남성/여성/부부의 주·부 불임 원인 + 불명확 원인 (0/1 flag).

우리는 어떻게 처리하나요? ☒ 전부 Int8 유지

왜 그렇게 하나요? 단독 상관관계는 약합니다 ($\pm 0.01 \sim 0.04$). 하지만 **조합**으로 쓰면 의미가 생겨요. 예: `cause_count = 여러 원인 동시`.



18-27. 불임 원인 Boolean 세부 (10개)

난관 질환, 남성 요인, 배란 장애, 여성 요인, 자궁경부 문제, 자궁내막증, 정자 농도/면역학적/운동성/형태 boolean.

우리는 어떻게 처리하나요?

✗ DROP 3개

- 21. 불임 원인 - 여성 요인 (전부 0, variance=0)
- 22. 불임 원인 - 자궁경부 문제 (1이 10건만, 과적합 위험)
- 25. 불임 원인 - 정자 면역학적 요인 (1이 1건만, 통계적 무의미)

☒ 유지 7개

난관, 남성, 배란, 자궁내막증, 정자 농도, 정자 운동성, 정자 형태

왜 그렇게 하나요? "자궁경부 문제" 10건 중 10건 전부 성공 0%는 신호처럼 보이지만, **10건은 너무 적어서** 모델이 과적합할 위험이 더 큼. "정자 면역학적" 1건은 말할 것도 없고요.

💡 파생변수 (Templeton 1996: 단독 약함, 조합 필수):

```

cause_count = sum(남은 7개 boolean)          # 원인 다중성
female_factor_strong = (난관+배란+자궁내막증 >= 2)
male_factor_severe   = (정자 농도+운동성+형태 >= 2) # Palermo 1992

```



28. 배아 생성 주요 이유

이게 뭔가요? 왜 배아를 만들었나. 심표로 구분된 복합 카테고리.

데이터에 어떤 값이 있나요?

현재 시술용:	233,732건
배아 저장용:	9,192건
NaN:	6,291건 (DI)
기증용, 현재 시술용:	3,784건
난자 저장용:	1,959건
...13개 카테고리 (복합값 많음)	

우리는 어떻게 처리하나요?  NaN → "해당없음" (DI 케이스) + 5개 multi-hot flag로 분해

```
is_현재시술용 = "현재 시술용" 포함
is_기증용     = "기증용" 포함
is_배아저장용 = "배아 저장용" 포함
is_난자저장용 = "난자 저장용" 포함
is_연구용     = "연구용" 포함
```

왜 그렇게 하나요? "기증용, 현재 시술용" 같은 복합값을 하나의 카테고리로 두면 정보 손실. 각 목적을 독립 flag로 분해하면 모델이 각 목적의 효과를 독립적으로 학습 가능.

12 34 29-38. 시술·임신·출산 횟수 (10개 — 문자열 숫자)

이게 뭔가요? 총/IVF/DI별로 시술 횟수, 임신 횟수, 출산 횟수. 전부 "0회", "1회", ..., "6회 이상" 형태.

데이터에 어떤 값이 있나요? 각 컬럼마다 7개 유니크 값 (0회~6회 이상).

우리는 어떻게 처리하나요?  문자열 → 정수 변환 + `is_censored` flag

```
"0회"    → 0
"1회"    → 1
...
"5회"    → 5
"6회 이상" → 6 + is_censored_{col} = 1 (상한 도달 표시)
```

왜 그렇게 하나요? "6회 이상"은 실제론 6회일 수도, 10회일 수도 있음. 그냥 6으로 넣으면 정보 손실. `is_censored` flag를 같이 달면 "이 값은 상한 도달이라 실제론 더 클 수 있다"를 모델이 알게 돼요.

 핵심 파생변수:

```
is_first_attempt = (총 시술 == 0)           # Templeton 1996
repeated_3plus   = (총 시술 >= 3)           # Templeton 1996 (p<0.001)
ever_delivered   = (총 출산 > 0)             # Templeton 1996, Barnett-Itzhaki 2020
                                                         ★ 이전 출산 경험은 강한 긍정 신호!
prev_birth_rate  = 총 출산 / (총 임신 + 1)
```

39-52. 배아/난자/정자 수량 (14개 — 수치형)

이게 뭔가요? 총 생성 배아 수, 이식된 배아 수, 저장된 배아 수, 미세주입 관련 4개, 해동된 배아/난자, 수집/저장/혼합 난자, 파트너/기증자 정자 혼합 수 등.

데이터에 어떤 값이 있나요?

- 최대값 51 (배아나 난자가 최대 51개까지)
- $p99 \approx 20$, $p99.9 \approx 30$
- 결측률 2.5% (전부 DI 케이스)

우리는 어떻게 처리하나요?  R1 규칙: DI → 0 (구조적 결측) + 나머지는 fold 내부 중앙값

왜 그렇게 하나요? DI 시술은 체외수정이 아니라 배아 자체를 안 만들어요. 그러니 "배아 수 = NaN"이 아니라 실질적으로 "배아 수 = 0". 이걸 0으로 명시하면 모델이 올바르게 학습.

 엄청 중요한 파생변수들:

비율 변수 (Palermo 1992, Templeton 1998)

```
icsi_ratio      = 미세주입 생성 배아 / (총 생성 배아 + 1)  # ICSI 효율
fertilize_yield = 미세주입 생성 / (미세주입 난자 + 1)      # 수정 효율
transfer_density = 이식된 배아 / (총 생성 배아 + 1)        # 이식 집중도
freeze_ratio    = 저장된 배아 / (총 생성 배아 + 1)         # 여분 배아 여유
```

난자 수 기반 (Sunkara 2011: 최적 ≈ 15개)

```
eggs_optimal      = (수집 신선 난자 10~20)  # 최적 구간
eggs_excess       = (수집 신선 난자 > 20)   # 과자극 역효과
low_ovarian_response = (수집 신선 난자 <= 3) # 저반응 (FSH 프록시)
eggs_x_age        = 난자 수 × 나이_ord      # 핵심 교호작용
```

이식 배아 수 (Templeton & Morris 1998 NEJM)

```
optimal_transfer = (이식된 배아 수 == 2)  # 4개 초과 수정 시 최적
over_transfer    = (이식된 배아 수 >= 3)  # 다태아 위험만 증가
```



17 53-56. 출처·기증자 나이 (4개) ★ 이 섹션 필독

이게 뭔가요?

- 53. 난자 출처 (본인 제공 / 기증 제공 / 알 수 없음)
- 54. 정자 출처 (본인/배우자 제공 / 기증 제공 / 미할당 / ...)
- 55. 난자 기증자 나이 (5개 구간 + 알 수 없음)
- 56. 정자 기증자 나이 (7개 구간 + 알 수 없음)

기증자 나이에 "알 수 없음"이 많은 이유

```
난자 기증자 나이 = "알 수 없음" 242,381건:
  본인 제공:      234,291건 (기증자 자체가 없음 - 구조적 결측)
  기증 제공:      1,799건 (진짜 결측)
  알 수 없음:     6,291건 (출처 불명, DI)

→ 96.7%는 "모르는" 게 아니라 "없는" 것!
```

우리는 어떻게 처리하나요?  Category 그대로 유지. 절대 보간 금지.

왜 그렇게 하나요? 만약 "알 수 없음"에 기증자 평균 나이(30세)를 채우면:

- 본인 난자 사용자 234,291명에게 "기증자 30세로 받았다"는 **가짜 정보 주입**
- 모델이 "모두가 기증 받은 것처럼" 왜곡 학습
- 본인(26%) vs 기증(32%) 성공률이 섞여서 정보 상실

엄청난 신호: 고령 × 기증 난자 교호작용

나이	본인 난자	기증 난자	차이
만18-34세	32.3%	30.7%	거의 같음
만35-37세	27.7%	31.8%	+4%p
만38-39세	21.3%	32.4%	+11%p
만40-42세	14.4%	32.5%	+18%p
만43-44세	6.2%	34.0%	+28%p ▲
만45-50세	2.6%	29.2%	+26%p ▲

고령이 기증 난자를 받으면 **성공률이 5배 이상 뛰는** 매우 강한 효과!

💡 이것 때문에 만드는 핵심 파생변수:

```
used_donor_egg    = (난자 출처 == "기증 제공")
used_donor_sperm  = (정자 출처에 "기증" 포함)
★ elderly_donor_egg = (나이_ord >= 3) & used_donor_egg ← Kawwass 2013 근거
donor_age_gap     = 환자 나이 중앙값 - 기증자 나이 중앙값
```

57-62. 시술 여부 Flag (6개)

이게 뭔가요?

- 57. 동결 배아 사용 여부
- 58. 신선 배아 사용 여부
- 59. 기증 배아 사용 여부
- 60. 대리모 여부
- 61. PGD 시술 여부 (99.1% NaN)
- 62. PGS 시술 여부 (99.2% NaN)

우리는 어떻게 처리하나요?

```
57~60: Int8 그대로 유지 (결측 2.5%만)
61~62: NaN → 0 변환 (시행 여부 flag로)
```

왜 그렇게 하나요? PGD/PGS는 99% 미시행. 하지만 1%만이라도 시행한 케이스는 특수 상황이므로 flag로 살립니다. PGD는 성공률 차이 미미해서 importance 낮으면 drop 후보.

63-67. 경과일 (5개) ★★★ 가장 강한 신호

63. 난자 채취 경과일 ✖ DROP

값이 전부 0이거나 NaN. variance=0이라 정보 제로.

64. 난자 해동 경과일 (99.4% NaN)

처리: R4 규칙 — 해동 난자 수 = 0 → -1 sentinel. 값 1,436건만 있어 importance 낮으면 drop 후보.

65. 난자 혼합 경과일 (21% NaN)

처리: R5 규칙 — 혼합 난자 수 = 0 → -1 sentinel.

66. 배아 이식 경과일 ★★★ 대회 최강 단일 신호

이게 뭔가요? 배아가 며칠간 배양된 후 이식됐는지. 배아 발달 단계의 지표.

데이터에 어떤 값이 있나요?

0일 (당일 이식):	24,904건 (성공률 25.1%)
1일:	6,053건 (18.7%)
2일 (cleavage):	35,078건 (21.2%)
3일 (cleavage):	57,924건 (25.9%)
4일:	4,504건 (34.4%)
5일 (blastocyst):	81,459건 (40.4%) ★ 최고
6일 (blastocyst):	2,773건 (30.0%)
7일:	90건 (41.1%)
NaN:	43,566건 (2.4%) ← 이식 안 함

우리는 어떻게 처리하나요? ✅ R2 규칙: NaN → -1 sentinel + **no_transfer** flag

△ 베이스라인 버그 수정:

```
# 베이스라인 (잘못됨):
df.loc[mask_no_transfer, "배아 이식 경과일"] = 0
# → NaN과 0일(당일이식)이 섞여버림

# v2 (정확):
no_transfer = df["이식된 배아 수"].fillna(0).eq(0)
df["no_transfer"] = no_transfer.astype(int)
df.loc[no_transfer, "배아 이식 경과일"] = -1 # sentinel (0과 구분)
```

왜 그렇게 하나요? 값 있음 30.6% vs NaN 2.4% — 13배 차이. 이 신호를 섞으면 정보 파괴.

💡 가장 강력한 파생변수:

```
★ blast_transfer = (배아 이식 경과일 >= 5) # Kawwass 2013
cleavage_transfer = (배아 이식 경과일 in {2,3})
no_transfer = (이식된 배아 수 == 0) # 성공률 0% 케이스
```

67. 배아 해동 경과일 (84.3% NaN)

처리: R3 규칙 — 해동 배아 수 = 0 → -1 sentinel + `no_frozen_transfer` flag. 신선 배아 vs FET(해동) 구분의 중요 지표.

🎯 파생변수 최종 종합 (30+ 개)

각 컬럼 설명에서 언급한 파생변수들을 여기 한 번에 모았습니다.

🌟 최우선 (논문 근거 강함)

파생변수	정의	근거
<code>blast_transfer</code>	배아 이식 경과일 ≥ 5	Kawwass 2013 (OR 1.17)
<code>eset_blast</code>	단일 이식 & blastocyst	Kawwass 2013 (OR 1.17 $\times$ 2.32)
<code>elderly_donor_egg</code>	만40+ & 기증 난자	Kawwass 2013, Templeton 1996
<code>ever_delivered</code>	총 출산 > 0	Templeton 1996, Barnett-Itzhaki 2020
<code>eggs_optimal</code>	난자 10~20개	Sunkara 2011
<code>no_transfer</code>	이식 배아 0	성공률 0% 케이스 분리
<code>has_blast</code>	특정 시술에 BLASTOCYST	Kawwass 2013
<code>has_repeat</code>	특정 시술에 :	내부 EDA (성공률 7.8%)

🌟 2순위 (신호 확인됨)

파생변수	정의
<code>is_first_attempt</code>	총 시술 == 0
<code>repeated_3plus</code>	총 시술 ≥ 3
<code>optimal_transfer</code>	이식 == 2
<code>has_ah</code>	특정 시술에 AH
<code>intended_multi_actual_single</code>	단일==0 & 이식==1
<code>cause_count</code>	원인 boolean 합
<code>has_icsi</code>	미세주입 난자 > 0
<code>low_ovarian_response</code>	난자 ≤ 3

비율 변수

파생변수	정의
<code>icsi_ratio</code>	ICSI 배아 / (총 생성 + 1)
<code>fertilize_yield</code>	ICSI 배아 / (ICSI 난자 + 1)
<code>transfer_density</code>	이식 배아 / (총 생성 + 1)
<code>freeze_ratio</code>	저장 배아 / (총 생성 + 1)
<code>prev_birth_rate</code>	출산 / (임신 + 1)
<code>prev_pregnancy_rate</code>	임신 / (시술 + 1)

정합성 Flag (라벨 노이즈 감지)

파생변수	정의
<code>flag_transfer_gt_total</code>	이식 > 총 생성
<code>flag_stored_gt_total</code>	저장+이식 > 총 생성
<code>flag_icsi_gt_transfer</code>	ICSI 이식 > 총 이식
<code>flag_mix_gt_collected</code>	혼합 > 수집+해동
<code>flag_di_with_embryo</code>	DI인데 배아 > 0
<code>flag_age_unknown</code>	나이 "알 수 없음"

복합 분해 (특정 시술 + 배아 이유)

특정 시술 유형 → `has_repeat`, `has_blast`, `has_ah` (3개)
배아 생성 주요 이유 → `is_현재시술용`, `is_기증용`,
`is_배아저장용`, `is_난자저장용`, `is_연구용` (5개)

교호작용

파생변수	정의
<code>eggs_x_age</code>	난자 수 × 나이_ord
<code>elderly_donor_egg</code>	(나이≥40) & 기증 난자
<code>donor_age_gap</code>	환자 나이 - 기증자 나이



최종 DROP 컬럼 정리 (4개)

#	컬럼	이유
21	불임 원인 - 여성 요인	전부 0 (variance=0)
22	불임 원인 - 자궁경부 문제	1이 10건만 (과적합)
25	불임 원인 - 정자 면역학적 요인	1이 1건만
63	난자 채취 경과일	NaN 외 전부 0

1차 제출 후 drop 검토

- PGD 시술 여부 (+2%p만 차이)
- 난자 해동 경과일 (값 1,436건만)
- 시술_시기_freq (importance 하위 25%면)



실행 체크리스트

- ☐ Step 0: Schema 정의 (pipeline/schema.py)
- ☐ Step 1: DROP 4개 제거
- ☐ Step 2: 문자열 → 숫자 (횟수 10개, 나이)
- ☐ Step 3: 범주 정규화 (특정 시술, 배란 유도)
- ☐ Step 4: R1~R6 도메인 결측 처리
- ☐ Step 5: 기증자 flag + 배아 이유 처리
- ☐ Step 6: 파생 flag 생성 (정합성 6 + 복합 분해 8 + gap 1)
- ☐ Step 7: 범주 union + 시술 시기 Frequency encoding
- ☐ Step 8: 파생변수 (팀원 B - 비율·교호작용 등 20+)
- ☐ Step 9: LGBM 5-fold CV → AUC + Feature Importance
- ☐ Step 10: importance 기반 불필요 컬럼 drop 결정
- ☐ Step 11: v2 제출

예상 최종 shape

원본:	256,351 × 69
- DROP 4개:	-4
+ 나이 ordinal + median (3 × 2):	+6
+ 횡수 is_censored flag (10):	+10
+ 결측 flag (no_transfer 등):	+4
+ 정합성 flag (6):	+6
+ 복합 분해 flag (3 + 5):	+8
+ 의도 vs 실제 gap:	+1
+ 기증 사용 flag (2):	+2
+ 시술_시기_freq:	+1 (원본 -1)

전처리 완료: 256,351 × ~100 피쳐

마지막으로

이 문서를 따라 한 번씩 처리하면:

1. 베이스라인 대비 +0.02~0.04 AUC 개선 기대 (단순 전처리만)
2. 파생변수까지 추가하면 목표 0.78~0.80 달성 가능
3. 이후는 모델 튜닝 + 앙상블 영역

진행 순서:

1. 이 문서로 전처리 파이프라인 코드 작성
2. LGBM 5-fold CV 돌려서 AUC 확인
3. Feature importance 로그 남기기
4. importance 낮은 컬럼 drop (시술 시기 freq, PGD 등)
5. 파생변수 추가 → 재학습 → 비교
6. XGBoost / CatBoost 추가 → 앙상블
7. 최종 제출

모두 화이팅! 🍀