

전처리 계획서 v2.2 (Day 1) - 8조 팔로피안

전처리 계획서 (Day 1, 8조 팔로피안)

작성일: 2026-04-23 담당: 팀원 A (전처리 파이프라인) 선행 문서: [architecture.md](#), [팀회의_브리핑.md](#), [데이터분석.txt](#) 후속 구현: [pipeline/schema.py](#) , [pipeline/clean_rules.py](#) ([architecture.md](#) §1 구조 따름)

0. 문서 간 역할 정리

문서	역할	이 계획서와의 관계
architecture.md	전체 파이프라인·디렉토리·전략 (거시)	§2-2, §2-3, §3을 실제 결정으로 박제
팀회의_브리핑.md	Day1~3 일정·역할 분담	Day1 오후 팀원 A 작업을 단계별로 분해
데이터분석.txt	왜 이렇게 접근하나 (방향)	이 계획서는 " 구체적으로 뭘 어떻게 " (실행)
baseline_lgbm_auc.py	현재 제출본 전처리 (AUC 0.74184)	이 계획서는 v2 전처리로 확장 하면서 오류 수정

1. 베이스라인 대비 변경·추가점 요약

항목	베이스라인(v1)	v2 (이 계획서)	근거
상수 컬럼 drop	✗ 없음	✓ 2개 drop, 3개 flag 변환	아래 §4
나이 인코딩	LGBM category 그대로	ordinal + median 병행	ordinal 정보 보존
도메인 규칙 결측	일부 (이식·해동·DI)	규칙 6종 확장	architecture.md §2-3
정합성 flag	1종 (<code>flag_transfer_gt_total</code>)	6종 확장	architecture.md §2-5
PGD/PGS/유전검사	(pass-through)	NaN→0 "시행 여부 flag"	아래 §4
배아 이식 경과일 NaN	0으로 채움 (당일이식과 혼동)	-1 sentinel + <code>no_transfer</code> flag	베이스라인 오류 수정
<code>is_repeat_cycle</code>	없음	특정 시술 유형 : 포함 flag	브리핑 §2 핵심 신호
특정 시술 유형 분해	24개 범주 그대로	공백 정규화 + <code>has_repeat/has_blast/has_ah</code> 3개 flag	§5-3, §7-2
배아 생성 주요 이유 분해	13개 범주 그대로 (복합값)	5개 multi-hot flag + NaN→"해당없음"	§6-4, §7-2
배란 유도 유형	4개 범주 (극희귀 2건 포함)	희귀값 → "알 수 없음" 통합	§5-3
기증자 정보	category 유지만	사용 여부 flag + 고령×기증 교호작용 가이드	§6-3
단일 이식 의도 vs 실제 gap	없음	<code>intended_multi_actual_single</code> flag	§7-3
초최소 boolean 추가 drop	유지	자궁경부 문제(10건), 정자 면역학적(1건) drop	§4-1 / §14
시술 시기 코드	LGBM category	Frequency encoding → importance 확인 후 drop 결정	§8 / §11
파생변수 (논문 근거)	2종 (transfer_density 등)	+3종: <code>icsi_ratio</code> / <code>ever_delivered</code> / <code>repeated_3plus</code>	§13 / §14

2. 전처리 전체 구조 (6단계)

[단계 0] Schema 정의	pipeline/schema.py	(fold 밖, 1회)
[단계 1] 컬럼 Drop	pipeline/clean_rules.py	(fold 밖, 1회)
[단계 2] Dtype 변환	pipeline/clean_rules.py	(fold 밖, 1회)
[단계 3] 도메인 결측 처리	pipeline/clean_rules.py	(fold 밖, 1회)
[단계 4] 정합성 flag 생성	pipeline/derive.py	(fold 밖, 1회)
[단계 5] 범주 통일	pipeline/clean_rules.py	(fold 밖, 1회)
————— (이하 모델링 단계, fold 내부) —————		
Target/Freq Encoding	pipeline/encoders.py	(fold 안)
Imputer / Scaler	pipeline/encoders.py	(fold 안)

원칙: 단계 0~5는 통계 기반이 아니므로 **fold 밖에서 1회 실행**. CV 시작 시점에 train/test 모두 전처리 완료 상태여야 함.

3. Schema 정의 (단계 0)

67개 컬럼을 6그룹 + DROP + 보조로 분류:

```

# pipeline/schema.py
SCHEMA = {
    "GROUP_ID": ["ID"],
    "GROUP_TARGET": ["임신 성공 여부"],

    "GROUP_CAT": [
        "시술 시기 코드", "시술 유형", "특정 시술 유형",
        "배란 유도 유형", "배아 생성 주요 이유",
        "난자 출처", "정자 출처",
    ],

    "GROUP_ORDINAL": [
        "시술 당시 나이", "난자 기증자 나이", "정자 기증자 나이",
        "총 시술 횟수", "클리닉 내 총 시술 횟수",
        "IVF 시술 횟수", "DI 시술 횟수",
        "총 임신 횟수", "IVF 임신 횟수", "DI 임신 횟수",
        "총 출산 횟수", "IVF 출산 횟수", "DI 출산 횟수",
    ],

    "GROUP_BOOL": [
        "배란 자극 여부", "단일 배아 이식 여부", "착상 전 유전 진단 사용 여부",
        "동결 배아 사용 여부", "신선 배아 사용 여부", "기증 배아 사용 여부",
        "대리모 여부",
        # 불임 원인 boolean (7개, v2.1: "여성 요인"/"자궁경부"/"정자 면역학적" drop)
        "불임 원인 - 난관 질환", "불임 원인 - 남성 요인", "불임 원인 - 배란 장애",
        "불임 원인 - 자궁내막증",
        "불임 원인 - 정자 농도",
        "불임 원인 - 정자 운동성", "불임 원인 - 정자 형태",
        # 범주형 원인 (6개) - 주/부 원인
        "남성 주 불임 원인", "남성 부 불임 원인",
        "여성 주 불임 원인", "여성 부 불임 원인",
        "부부 주 불임 원인", "부부 부 불임 원인",
        "불명확 불임 원인",
    ],

    "GROUP_NUMERIC": [
        "총 생성 배아 수", "미세주입된 난자 수", "미세주입에서 생성된 배아 수",
        "이식된 배아 수", "미세주입 배아 이식 수",
        "저장된 배아 수", "미세주입 후 저장된 배아 수",
        "해동된 배아 수", "해동 난자 수",
        "수집된 신선 난자 수", "저장된 신선 난자 수",
        "혼합된 난자 수", "파트너 정자와 혼합된 난자 수",
        "기증자 정자와 혼합된 난자 수",
        "난자 해동 경과일", "난자 혼합 경과일",
        "배아 이식 경과일", "배아 해동 경과일",
        "임신 시도 또는 마지막 임신 경과 연수",
    ],

    "GROUP_DROP": [
        "불임 원인 - 여성 요인", # train/test 전부 0 (variance=0)
        "난자 채취 경과일", # train/test 전부 0 or NaN (variance=0)
        "불임 원인 - 자궁경부 문제", # 1값 10건만 (과적합 위험)
        "불임 원인 - 정자 면역학적 요인", # 1값 1건만 (통계적 무의미)
    ],
}

```

```
# 특수 취급 (NaN→0 후 "시행 여부 flag"로 재해석)
"GROUP_TRY_FLAG": [
    "착상 전 유전 검사 사용 여부",    # NaN 99% / 1 = 1% → 0 = 미시행, 1 = 시행
    "PGD 시술 여부",                  # NaN 99% / 1 = 1%
    "PGS 시술 여부",                  # NaN 99% / 1 = 1%
],
}
```

4. 단계 1: 컬럼 Drop

4-1. 완전 drop (4개)

컬럼	분포	실측 신호	이유
불임 원인 - 여성 요인	전부 0	—	variance=0, 정보 없음
난자 채취 경과일	NaN 22% + 나머지 전부 0	—	사실상 상수
불임 원인 - 자궁경부 문제	0: 256,341 / 1: 10	10건 전부 성공 0%	과적합 위험 (통계적 유의미성 부족)
불임 원인 - 정자 면역학적 요인	0: 256,350 / 1: 1	1건	통계적 무의미

HTML 분석([feature_summary.html](#))에서도 동일 drop 권고. §14 참조.

4-2. NaN→0 변환 후 flag로 활용 (3개)

베이스라인에서 그냥 두면 LGBM이 NaN으로 취급. 하지만 1%의 시행 경험은 신호일 수 있음.

착상 전 유전 검사 사용 여부	NaN → 0 (미시행),	1 유지 (시행)
PGD 시술 여부	NaN → 0,	1 유지
PGS 시술 여부	NaN → 0,	1 유지

→ 제출 후 feature importance 낮으면 drop, 높으면 유지.

5. 단계 2: Dtype 변환

5-1. 횡수형 문자열 → 정수 + 보조 flag (10개 컬럼)

"0회" → 0, "1회" → 1, ..., "5회" → 5, "6회 이상" → 6

추가 flag:

```
is_censored_{col} = (원본값 == "6회 이상").astype(int) # 상한 도달 flag
```

대상: 총/IVF/DI 시술 횟수, 총/IVF/DI 임신 횟수, 총/IVF/DI 출산 횟수, 클리닉 내 총 시술 횟수.

5-2. 나이 구간 → ordinal + median 병행

```
AGE_MAP_ORD = {
    "만18-34세": 0, "만35-37세": 1, "만38-39세": 2,
    "만40-42세": 3, "만43-44세": 4, "만45-50세": 5,
    "알 수 없음": -1,
}
AGE_MAP_MED = {
    "만18-34세": 26.0, "만35-37세": 36.0, "만38-39세": 38.5,
    "만40-42세": 41.0, "만43-44세": 43.5, "만45-50세": 47.5,
    "알 수 없음": np.nan,
}
```

→ 컬럼 `시술 당시 나이_ord`, `시술 당시 나이_med` 2개 생성. 같은 방식으로 기증자 나이 2종도 처리.

5-3. 범주형 정규화 (표기 통일·희귀값 통합)

(A) 특정 시술 유형 공백 정규화

실데이터에 공백만 다른 중복 표기 존재:

"ICSI / BLASTOCYST:IVF / BLASTOCYST"	→ 6건	
"ICSI / BLASTOCYST :IVF / BLASTOCYST"	→ 4건	← 콜론 앞 공백만 다름
"ICSI / BLASTOCYST :ICSI"	→ 1건	← 동일

처리:

```
df["특정 시술 유형"] = (df["특정 시술 유형"]
    .astype(str)
    .str.replace(r"\s+", "", regex=True)    # 모든 공백 제거
    .str.replace("/", " / ")                # 슬래시 주변 단일 공백 정규화
)
```

(B) 배란 유도 유형 극희귀값 통합

train에 "세트로타이드 (억제제)" 1건, "생식선 자극 호르몬" 1건만 존재. test에는 아예 없음 → 학습 의미 無.

```
rare = df["배란 유도 유형"].value_counts()
rare_vals = rare[rare < 10].index          # 극희귀
df["배란 유도 유형"] = df["배란 유도 유형"].replace(
    dict.fromkeys(rare_vals, "알 수 없음")
)
```

결과: 사실상 2값 ("기록되지 않은 시행", "알 수 없음"). Boolean `is_recorded` 로 단순화 고려 가능.

5-4. Boolean dtype 통일

현재 `int64` / `float64` 혼재 → 전부 `Int8` (pandas nullable) 로 통일.

6. 단계 3: 도메인 규칙 기반 결측 처리

중요: 베이스라인의 `apply_domain_rules()` 는 규칙이 4개뿐. 이 계획서에서 **6종으로 확장**하고, **배아 이식 경과일 0 해석 오류도 수정**.

6-1. 수정: 배아 이식 경과일 0 vs NaN 구분

실제 데이터 분해:

상태	건수	성공률
경과일 값 있음 (1~7일 + 0일 당일이식 포함)	212,785	30.6%
경과일 NaN + 이식된 배아 수 == 0 (이식 안 함)	36,535	≈0%
경과일 NaN + 이식된 배아 수 == NaN (DI)	6,291	≈0%
경과일 NaN인데 이식된 배아 > 0 (이상)	740	—

→ NaN 전체 성공률 2.4% vs 값 있음 30.6%. 이 차이가 가장 큰 단일 신호.

```
# 베이스라인 (부정확): NaN을 0으로 채워서 "당일 이식(0일)"과 혼동
df.loc[mask_no_transfer, "배아 이식 경과일"] = 0

# v2 (수정):
no_transfer = df["이식된 배아 수"].fillna(0).eq(0)
df["no_transfer"] = no_transfer.astype(int)
df.loc[no_transfer, "배아 이식 경과일"] = -1 # sentinel (0일과 구분)
```

근거: 배아 이식 경과일 == 0 케이스 24,904건은 실제로 이식된 배아 수 > 0 (당일 이식 = zygote/pronuclear stage). 0을 "이식 없음"으로 처리하면 신호 왜곡.

6-2. 규칙 6종 (v2)

#	조건	대상 컬럼	처리	보조 flag
R1	시술 유형 == DI	배아·난자·미세주입 수량 18개	NaN → 0	—
R2	이식된 배아 수 == 0 or NaN	배아 이식 경과일	NaN → -1	no_transfer
R3	해동된 배아 수 == 0 or NaN	배아 해동 경과일	NaN → -1	no_frozen_transfer
R4	해동 난자 수 == 0 or NaN	난자 해동 경과일	NaN → -1	—
R5	혼합된 난자 수 == 0 or NaN	난자 혼합 경과일	NaN → -1	—
R6	총 임신 횟수 == 0회	임신 시도 경과 연수	NaN → -1	first_attempt

→ `pipeline/clean_rules.py` 에 규칙 테이블 dict로 선언 후 loop 적용 (architecture.md §1의 "데이터 주도" 원칙).

6-3. 기증자(난자/정자) 정보 — 보간 금지·구조적 결측 유지

핵심 원칙: "알 수 없음"에 기증자 평균 나이 등을 채워 넣으면 안 된다. 구조적 결측(본인 제공)을 기증 케이스와 섞으면 모델이 왜곡 학습.

데이터 구조

난자 기증자 나이 == "알 수 없음" 242,381건의 실제 구성:

난자 출처	건수	의미
본인 제공	234,291	구조적 결측 (기증자가 없음)
기증 제공	1,799	진짜 결측 (기증받았으나 나이 불명)
알 수 없음	6,291	출처 자체 불명 (DI 시술)

→ 96.7%는 기증자 없음이지 "모르는" 게 아님.

발견된 강력한 신호: 고령 × 기증 난자 교호작용

환자 나이	본인 난자	기증 난자	차이
만18-34세	32.3%	30.7%	~0
만40-42세	14.4%	32.5%	+18%p
만43-44세	6.2%	34.0%	+28%p
만45-50세	2.6%	29.2%	+26%p

→ 고령일수록 기증 난자가 성공률을 5배 이상 끌어올림. 베이스라인은 이 교호작용 포착 못 함.

전처리 처리 (이 단계에서 할 것)

```
# 1) "알 수 없음"을 그대로 category 유지 (보간 금지)
#     LGBM native category로 학습 → 본인/기증/진짜불명 자동 구분

# 2) 사용 여부 flag (구조적 신호 추출)
df["used_donor_egg"] = df["난자 출처"].astype(str).eq("기증 제공").astype(int)
df["used_donor_sperm"] = df["정자 출처"].astype(str).str.contains("기증").astype(int)
```

파생변수 단계로 이관 (팀원 B, §13)

```
elderly_donor_egg = (나이_ord >= 3) & used_donor_egg # 교호작용
donor_egg_age_ord = 기증자 나이 ordinal (기증 케이스만 유효)
```

진짜 결측 1,799건은 전체의 0.7% → 보간 효과 미미. 그대로 category 유지 권장. (필요 시 fold 내부에서 기증 케이스 중앙값만 보간 — leakage 방지)

6-4. 배아 생성 주요 이유 NaN 처리

NaN 6,291건 = 전부 DI 시술. DI는 배아 자체를 생성하지 않으므로 구조적 결측.

```
df["배아 생성 주요 이유"] = df["배아 생성 주요 이유"].fillna("해당없음")
```

→ "해당없음"을 별도 카테고리 유지. 이후 §7-2에서 multi-hot 분해.

7. 단계 4: 파생 Flag 생성

7-1. 정합성 Flag (6종)

architecture.md §2-5의 anomaly flag 반영:

```
flag_transfer_gt_total    = (이식된 배아 수 > 총 생성 배아 수)
flag_stored_gt_total      = (저장된 배아 + 이식된 배아 > 총 생성 배아)
flag_icsi_gt_transfer     = (미세주입 배아 이식 수 > 이식된 배아 수)
flag_mix_gt_collected    = (혼합된 난자 > 수집 신선 + 해동 난자)
flag_di_with_embryo       = (시술 유형 == DI AND 총 생성 배아 > 0)
flag_age_unknown          = (시술 당시 나이 == "알 수 없음")
```

→ 각 flag는 독립 피쳐. Feature importance 높으면 **라벨 노이즈 신호**로 해석.

⚠ 쓰면 안 되는 flag: (IVF 시술 + DI 시술) ≠ 총 시술 은 "6회 이상" 상한 근사로 인한 **가짜 모순** 2,564건 → flag로 쓰지 말고 **is_censored_total** (원본이 "6회 이상") 하나만 사용.

7-2. 복합 카테고리 분해 Flag

범주 하나에 여러 의미가 뭉쳐 있는 컬럼을 **부품으로 해체**. 신호 희석 → 분리 포착.

(A) 특정 시술 유형 → 3개 flag

실데이터 확인:

Flag	조건	성공률 변화	건수
has_repeat	":" 포함 (반복 주기)	26% → 7.8% ↓	5,047
has_blast	"BLASTOCYST" 포함	26% → 36.1% ↑	2,868
has_ah	"AH" 포함 (Assisted Hatching)	26% → 20.8% ↓	1,092

```
s = df["특정 시술 유형"].astype(str)
df["has_repeat"] = s.str.contains(":").astype(int)
df["has_blast"]  = s.str.contains("BLASTOCYST").astype(int)
df["has_ah"]     = s.str.contains(r"\bAH\b", regex=True).astype(int)
```

→ §5-3 공백 정규화 이후 적용.

(B) 배아 생성 주요 이유 → 5개 multi-hot flag

복합 카테고리("기증용, 현재 시술용" 등)를 해체:

```
s = df["배아 생성 주요 이유"].astype(str)
df["is_current_use"] = s.str.contains("현재 시술용").astype(int)
df["is_donation_use"] = s.str.contains("기증용").astype(int)
df["is_embryo_store"] = s.str.contains("배아 저장용").astype(int)
df["is_oocyte_store"] = s.str.contains("난자 저장용").astype(int)
df["is_research_use"] = s.str.contains("연구용").astype(int)
```

→ 원본 **배아 생성 주요 이유** 는 category로 유지 + 분해 flag 병행.

7-3. 의도 vs 실제 Gap Flag

단일 배아 이식 여부 (의도)와 **이식된 배아 수** (실제)의 불일치:

단일 이식	이식 배아 수	건수	해석
1	1	58,360	정상 (의도 = 실제)
1	2	21	모순
0	1	35,431	다중 의도였는데 1개만 이식 (중간 탈락)
0	2	110,824	정상 다중

```
df["intended_multi_actual_single"] = (  
    (df["단일 배아 이식 여부"] == 0) & (df["이식된 배아 수"] == 1)  
).astype(int)
```

→ "다중 이식 의도했으나 실제 1개만 이식됨" = **배아 수 부족·탈락 신호**.

8. 단계 5: 범주 통일

```
for col in GROUP_CAT:  
    all_cats = pd.api.types.union_categoricals(  
        [train[col].astype("category"), test[col].astype("category")]  
    ).categories  
    train[col] = train[col].astype("category").cat.set_categories(all_cats)  
    test[col] = test[col].astype("category").cat.set_categories(all_cats)
```

unseen category 방지. **Target/Frequency Encoding**은 여기서 하지 않음 (fold 내부 단계).

8-1. **시술 시기 코드** 특별 정책 (Frequency encoding → importance 평가)

7개 익명화 코드(TRZKPL, TRDQAZ 등)로 균등 분포. HTML 분석은 "임상 의미 없음 → DROP" 권고했으나, 병원/시기 고유값 가
능성 보존을 위해 **Frequency encoding 후 importance 확인** 타협안 채택.

```
# fold 내부 (leakage 방지)  
freq_map = X_tr["시술 시기 코드"].value_counts(normalize=True)  
X_tr["시술_시기_freq"] = X_tr["시술 시기 코드"].map(freq_map).fillna(0)  
X_va["시술_시기_freq"] = X_va["시술 시기 코드"].map(freq_map).fillna(0)  
X_test["시술_시기_freq"] = X_test["시술 시기 코드"].map(freq_map).fillna(0)
```

평가 기준 (§11 체크포인트에서 확인):

- 1차 제출 후 LGBM feature importance 순위
- 시술_시기_freq** 가 하위 25%에 들면 → **다음 제출부터 drop**
- 상위면 유지 + Target Encoding 추가 실험

→ 원본 **시술 시기 코드** category는 **frequency encoding 대체**로 제거 (중복 방지).

9. 전처리 완료 후 기대 shape

원본: 256,351 × 69

- ID/TARGET 분리
- DROP 4개 (여성 요인, 채취 경과일, 자궁경부, 정자 면역): -4
- + 나이 ordinal+median (3 × 2): +6
- + 횡수 is_censored flag (10개): +10
- + 결측 flag (no_transfer, first_attempt 등): +4
- + 정합성 flag (6개): +6
- + 복합 분해 flag (특정 시술 3 + 배아 이유 5): +8
- + 의도 vs 실제 gap flag: +1
- + 기증 사용 flag (난자·정자): +2
- + 시술_시기_freq (시술 시기 코드 대체): +1 (원본 -1 → 실질 ±0)

전처리 완료: 256,351 × ~100 (피쳐) + ID + target

파생변수(**fertilize_yield**, **transfer_density**, **elderly_donor_egg**, **donor_age_gap** 등)는 **별도 단계 (feature engineering)**로 구분 → 팀원 B 담당.

10. Leakage 체크리스트 (반드시 준수)

작업	Fold 밖 (1회)	Fold 안 (5회)
상수 컬럼 drop	✓	
문자열 → 숫자 고정 매핑	✓	
나이 구간 → 중앙값/ordinal 고정 매핑	✓	
도메인 규칙 (DI→0, R1~R6)	✓	
정합성 flag	✓	
범주 union	✓	
행 내부 비율 (팀원 B 파생변수)	✓	
Target Encoding	✗	✓ OOF fit
Frequency Encoding	✗	✓ fold train fit
Imputer (평균/중앙값 보간)	✗	✓ fold train fit
Scaler (MLP용)	✗	✓ fold train fit

11. 체크포인트 & 결과물

파일 산출물

```
pipeline/
├── schema.py          ← §3 SCHEMA dict
├── clean_rules.py     ← §4·§5·§6·§8 (drop, dtype, 범주 정규화, 결측, 범주 union)
└── derive_core.py    ← §7 파생 flag (정합성·복합 분해·gap)
                        팀원 B의 derive.py(비율·교호작용)와 구분
```

검증 체크 (코드 작성 후)

1. train/test shape 일치 (피쳐 컬럼 동일)
2. 범주형 dtype이 category이고 categories 동일
3. 결측률 로그: 단계별 before/after 비교
4. 상수 컬럼 잔류 없음 (nunique() == 1인 컬럼 0개)
5. dtype 일관성 (int8/float64/category/object)
6. 시술_시기_freq 컬럼 importance 하위 25% 여부 → drop 결정 (§8-1)

12. 팀원 간 인수인계

산출물	팀원 A →	활용
전처리 완료 <code>X_train</code> , <code>X_test</code>	팀원 B	<code>add_row_features()</code> 확장 (blast_transfer, is_repeat_cycle, eset_blast 등)
<code>GROUP_CAT</code> 리스트	팀원 C	LGBM <code>categorical_feature</code> 인자로 전달
결측/정합성 flag 컬럼 목록	팀원 A → A	시각화·타겟 관계 분석

13. 다음 단계 (전처리 이후)

1. EDA 심화 (팀원 A): 전처리 결과물로 컬럼별 타겟 관계·상관·분포 시각화 → `reports/eda_target.md`
2. 파생변수 v2 (팀원 B): 아래 추가 (특히 **고령×기증 교호작용**)

```
# 기본 비율·flag
blast_transfer      = (배아 이식 경과일 >= 5)
is_first_attempt    = (총 시술 횟수 == 0)
eset_blast          = (단일 배아 이식==1) & (blast_transfer==1)
cause_count         = sum(불임 원인 boolean 7개)      # v2.1: drop 반영 후 7개
fertilize_yield     = 미세주입에서 생성된 배아 / 미세주입된 난자
transfer_density    = 이식된 배아 / 총 생성 배아
freeze_ratio        = 저장된 배아 / 총 생성 배아
prev_birth_rate     = 총 출산 / 총 임신

# v2.1 추가 (HTML 분석 + 논문 근거, v2.2에서 인용 정정)
icsi_ratio          = 미세주입에서 생성된 배아 / (총 생성 배아 + 1)  # Palermo 1992 (ICSI 기법 원
ever_delivered      = (총 출산 횟수 > 0)                          # Templeton 1996, I
repeated_3plus      = (총 시술 횟수 >= 3)                          # Templeton 1996 (

# 기증자 교호작용 (핵심 신호)
elderly_donor_egg   = (나이_ord >= 3) & used_donor_egg      ← 핵심 교호작용
donor_age_gap       = 환자 나이 중앙값 - 기증자 나이 중앙값 (기증 케이스만)
```

3. **모델 재학습** (팀원 C): LGBM으로 재실험, AUC 비교 + feature importance 로그

4. **하이브리드 앙상블** (Day 6, 팀원 C): LGBM + Logistic Regression 스택킹 시도

LR 전용 전처리 (LGBM과 별도):

```
NaN 채우기      → Imputer (중앙값/최빈값), fold 안에서 fit
범주형 인코딩   → OneHotEncoder (GROUP_CAT)
스케일링        → StandardScaler (GROUP_NUMERIC, GROUP_ORDINAL)
```

앙상블 방식:

```
1안) 가중 평균: final = 0.7 * pred_lgbm + 0.3 * pred_lr
2안) 스택킹:   [LGBM 00F, LR 00F] → 메타 LR → 최종 예측
```

진행 조건: Day 5까지 LGBM 튜닝 완료 시에만 진행. AUC +0.001 미만이면 미채택.

LR이 보완할 수 있는 부분:

- 불임 원인 boolean 9개의 선형 조합
- 횟수형 컬럼의 단조 관계 (정규화로 노이즈 억제)

수치형 극단값 대응 (향후 MLP 단계)

현재 LGBM(트리)은 outlier 영향 적음 → **당장 처리 불필요**. MLP 추가 시점에 적용:

컬럼	max	p99	권장 처리
총 생성 배아 수	51	20	<code>log1p</code> or <code>winsorize(p99)</code>
미세주입된 난자 수	51	22	동일
혼합된 난자 수	51	27	동일

14. HTML 분석 결과(v2.1)와의 차이점

이번대회자료/feature_summary.html, feature_missing_detail.html, correlation_heatmap.html 을 참고하여 수용/거부/보류 결정.

14-1. 수용한 항목

HTML 제안	반영 섹션	근거
자궁경부 문제·정자 면역학적 요인 DROP	§4-1	1값이 각 10건/1건 → 과적합 위험
icsi_ratio 파생변수	§13	Palermo et al., 1992 Lancet (ICSI 기법 원전)
ever_delivered 파생변수	§13	Templeton et al., 1996 Lancet + Barnett-Itzhaki 2020
repeated_3plus 파생변수	§13	Templeton et al., 1996 Lancet (시술 횟수↑ 성공률↓, $p<0.001$)
시술 시기 코드 DROP	§8-1 타협	Frequency encoding → importance 확인 후 drop 결정

14-2. 거부한 항목 (HTML 방식이 틀린 이유)

HTML 제안	실측 검증	왜 거부했는가
나이 "알수없음" → ordinal 3 (중양값)	329건 성공률 0%	중양값(만38-39세, 21.7% 성공률)으로 대체 시 강한 실패 신호 소실 → sentinel -1 유지
기증자 나이 "알수없음" → 최빈값	242,381건 중 96.7%가 본인 남자 사용자	본인 사용자 234,291명에게 가짜 기증자 나이 주입 → category 유지
배아 이식 경과일 NaN → 중양값	NaN 성공률 2.4% vs 값 있음 30.6% (13배 차이)	중양값(≈3일, 25.9%)으로 덮으면 핵심 신호 소실 → -1 sentinel
착상 전 유전 검사 DROP	값=1 성공률 14.8% vs NaN 26% (-11%p)	NaN→0 flag 변환으로 신호 살림
임신 경과 연수 DROP	NaN 26% vs 값 21.7% (-4%p)	first_attempt flag로 유효
배아 해동 경과일 DROP	NaN(Fresh) 26% vs 값(FET) 22.9%	Fresh/FET 구분 → R3 규칙으로 flag 처리
PGS DROP	값=1 성공률 20.6% vs NaN 26% (-5%p)	약하지만 flag로 살림

핵심 차이: HTML은 결측치 중심(99% 결측치이면 drop), 계획서는 도메인 구조 중심(구조적 결측치는 정보 자체).

14-3. 보류 (초기 실험 후 결정)

항목	초기 처리	평가 기준
PGD 시술 여부	NaN→0 flag	+2%p 미미 차이 → importance 낮으면 drop
난자 해동 경과일	R4 규칙 (NaN→-1)	값 1,436건만 → importance 낮으면 drop
시술 시기 코드	Frequency encoding	importance 하위 25% 시 drop

14-4. HTML에 없던 계획서 고유 기여

항목	HTML 커버 여부
특정 시술 유형 분해 (has_repeat/has_blast/has_ah)	✗ (Label encoding만)
배아 생성 주요 이유 multi-hot (5개 flag)	✗
특정 시술 유형 공백 정규화	✗
의도 vs 실제 gap flag	✗
고령×기증 난자 교호작용	✗
배아 이식 경과일 NaN 재해석	✗ (중앙값 대체)
정합성 flag 6종	✗
"6회 이상" is_censored flag	✗

14-5. 참고 문헌 (v2.2: 12선 논문 검증 결과로 정정)

상세 요약은 [관련논문_12선.md](#) 참조. 아래는 계획서에서 인용된 논문의 **정확한 서지**와 각 파생변수·전처리 결정의 **정정된 근거**.

A. 도메인 지식 (7편)

#	정확한 인용	주요 발견 (대회 관련)	계획서 활용
1	Palermo G et al. <i>Lancet</i> . 1992;340(8810):17-18	ICSI 기법 최초 성공 (4 임신/8 cycle)	<code>icsi_ratio</code> 개념적 근거
2	Toner JP et al. <i>Fertil Steril</i> . 1991;55(4):784-791	basal FSH > age 예측력	난소 예비력 프록시 개념 (우리 데이터엔 FSH 없음)
3	Templeton A, Morris JK, Parslow W. <i>Lancet</i> . 1996;348(9039):1402-1406	대규모 36,961 cycles: 나이 25-30세 최고 / 불임 기간↑ 성공률↓ / 시술 횟수↑ 성공률↓ (p<0.001) / 이전 출산 유의 / 기증 난자 30+에서 p=0.04 유의	<code>ever_delivered</code> , <code>repeated_3plus</code> , <code>elderly_donor_egg</code> 의 핵심 근거
4	Templeton A, Morris JK. <i>N Engl J Med</i> . 1998;339(9):573-577	4개 초과 수정 시 2-배아 vs 3-배아 출산율 차이 없음 (OR 다태아 1.6)	<code>optimal_transfer = 이식==2</code>
5	Sunkara SK et al. <i>Hum Reprod</i> . 2011;26(7):1768-1774	400,135 cycles: 난자 수 최적 ≈ 15, 20개 초과 감소. 15개 기준 <40세 40% vs 40+ 16%	<code>eggs_optimal</code> , 나이×난자수 교호작용
6	Domar AD et al. <i>Fertil Steril</i> . 2010;94(4):1457-1459	IVF dropout 원인: 스트레스 39% (재정 아님)	<code>repeated_3plus</code> 직접 근거 아님 (간접)
7	Kawwass JF et al. <i>JAMA</i> . 2013;310(22):2426-2434	기증 난자 cycle 증가, 기증자 평균 28세 / 수혜자 41세. Day-5 이식 OR 1.17, 단일 이식 OR 2.32	<code>eset_blast</code> , <code>elderly_donor_egg</code> 핵심 근거

B. ML 예측 모델 (5편)

#	정확한 인용	우리 대회와의 관련성
8	Goyal A et al. <i>PLoS One</i> . 2022;17(5):e0267554	RF (AUC 0.72) > LR (0.68) / 상위 feature: 자극 프로토콜, 동결 배아 수, 나이
9	Barnett-Itzhaki Z et al. <i>J Assist Reprod Genet</i> . 2020;37(10):2405-2412 (PMC7550518)	NN AUC 0.79-0.86 > LR 0.46-0.72. 3분위수 범주화 전처리. 이전 임신력의 광범위한 예측력 입증
10	Hassan AA et al. <i>BMC Pregnancy Childbirth</i> . 2023 (PMC10294395)	★ 우리 대회와 가장 유사. LGBM 주기 후 val AUC 0.816 (우리 목표 0.78-0.80과 일치). simple deletion 전처리로 충분. 상위 feature: maternal age, AMH, basal FSH, basal P, basal E2, infertility duration
11	Nat Commun 2025 (s41467-025-58744-z)	센터별 특화 ML > 전국 통합 모델 (p<0.05). → 시술 시기 코드 Frequency encoding 강화 근거
12	<i>Biomedicines</i> . 2025;13(11):2768 (PMC 41301861)	XGBoost 9-variable 모델 internal AUC 0.876, external 78.3% . 여성 나이 = 지배적 feature . AMH, BMI = workhorse

C. 파생변수 ↔ 논문 근거 매핑 (정정판)

파생변수	근거 논문	비고
ever_delivered	Templeton 1996 Lancet, Barnett-Itzhaki 2020	✗ Toner 1991은 FSH 논문이라 근거 아님
elderly_donor_egg	Templeton 1996 (p=0.04), Kawwass 2013 (OR 1.17 / 2.32)	가장 강한 근거
eset_blast = 단일 + day-5	Kawwass 2013	최적 조합
optimal_transfer = 이식==2	Templeton & Morris 1998 NEJM	—
eggs_optimal = 10~20 난자	Sunkara 2011	비선형 — LGBM 자동 처리
low_ovarian_response = 난자 ≤3	Toner 1991	FSH 대체 프록시
cause_count	Templeton 1996	단독 약함, 조합으로만 의미
icsi_ratio	Palermo 1992	기법 원전 (간접 근거)
repeated_3plus	Templeton 1996	✗ Domar 2010은 dropout 연구라 근거 약함

D. v2.2 인용 정정 내역

이전 (v2.1)	수정 (v2.2)
Templeton & Morris, 1998 Lancet — 배아 효율	Templeton et al., 1996 Lancet (예후 요인) / Templeton & Morris, 1998 NEJM (2-배아 이식) 구분
Toner 1991 — 이전 출산 경험	❌ 주제 오인. 실제로는 FSH > age . 이전 출산은 Templeton 1996
Domar 2012 Fertil Steril	✅ 연도 정정 → 2010
Royston & White 2011 — 중앙값 대체 근거	❌ MICE (다중 대체) 논문. 중앙값 대체 근거 아님 (HTML 오인용) — 제거
추가	Hassan 2023 (LGBM AUC 0.816), Nature Comm 2025 (center-specific), Biomedicines 2025 (XGB 0.876)

핵심 요약 (v2.2) 베이스라인(v1) 대비 변경사항:

- **drop 4 + flag 전환 3** (상수·희소 컬럼 정리)
- **도메인 규칙 6종** (DI→0, no_transfer, first_attempt 등)
- **범주 정규화** (특정 시술 유형 공백, 배란 유도 유형 희귀값 통합)
- **복합 카테고리 분해** (특정 시술 3 flag + 배아 이유 5 flag)
- **정합성 flag 6종, 의도vs실제 gap flag**
- **기증자 정보:** 보관 금지 + 사용 여부 flag (교호작용은 §13 팀원 B 단계)
- **나이 ordinal/median 병행**
- **시술 시기 코드 Frequency encoding → importance 평가 후 drop 결정** (Nature Comm 2025 지지)
- **파생변수 3종 추가** (icsi_ratio / ever_delivered / repeated_3plus)
- **v2.2: 논문 인용 검증 및 정정** — Templeton 1998 Lancet → 1996 Lancet / Toner 1991 (주제 정정) / Domar 2012 → 2010 / Royston&White 제거 / Hassan 2023·Nat Comm 2025·Biomedicines 2025 추가

현실적 AUC 목표 0.78-0.80 재확인 (Hassan 2023 LGBM 주기후 val 0.816, Biomedicines 2025 external 78.3%)

pipeline/schema.py + pipeline/clean_rules.py 로 구현 예정. **단계 0~5는 fold 밖에서 1회**, 인코딩/보관/스케일링은 fold 내부.